

모델 평가 손계산 활동지

AI가 화면에 보여 주던 점수(R^2 , 정확도, 향상도)를 종이 위에서 직접 만들어 봅니다. 사칙연산과 나눗셈이면 충분합니다. 부마다 기본 개념 → 예제(풀이 포함) → 연습 문제 → 스스로 풀기 → 수업 실측 해석의 순서로 되어 있습니다. 문제를 풀다가 막히면 그 부의 개념 카드로 돌아가 분모가 무엇인지부터 확인합니다.

📌 활동지 규칙

계산 과정을 지우지 않습니다. 과정이 곧 점수입니다. 다만 적힌 활동지는 검산할 수 없습니다. 막히면 표의 빈칸부터 채웁니다. 정답은 접힌 상자 안에 있으니, 먼저 끝까지 푼 뒤에 펼칩니다. 지필평가의 계산 문항은 이 활동지의 흐름 그대로 출제되며, 수치는 수업에서 함께 본 실측값에서만 나옵니다.

1부 회귀 평가 — 오차 · MSE · R^2



2부 분류 평가 — 혼동행렬 · 세 지표 · 기준선



3부 연관 분석 — 지지도 · 신뢰도 · 향상도



4부 군집 평가 — 거리 · 정규화 · 실루엣

1부 · 8차시

회귀 모델의 평가 — 오차에서 R^2 까지

개념 네 계단

① 오차

실제값 - 예측값

이 예측은 얼마나, 어느 쪽으로 빗나갔나. 부호가 있다.

② 부호 없애기

|오차| 또는 오차²

양수와 음수가 상쇄되지 않게. 절댓값의 평균이 MAE.

③ MSE


제곱오차의 합 ÷ 개수

평균적으로 얼마나 빗나가나. 큰 실수 하나에 민감하다.

④ R^2

$1 - (SSE \div SST)$

SSE = 내 모델의 제곱오차 합,
SST = 평균만 찍는 모델의 제곱오차 합. "평균보다 얼마나 나은가".



오차는 세로 거리, 제곱오차는 그 거리를 한 번으로 하는 정사각형의 넓이입니다.

예제 1 오차 · MAE · MSE

내가 만든 기온 예측기의 4일 기록입니다. 오차의 합, MAE, MSE를 구합니다.

	월	화	수	목
실제(°C)	22	25	27	24
예측(°C)	23	24	27	26
오차(실제-예측)	-1	+1	0	-2
오차	1	1	0	2
오차 ²	1	1	0	4

- 오차를 그냥 더하면 $(-1) + 1 + 0 + (-2) = -2$. 이 값만 보면 4일에 2도 빗나간 것처럼 보이지만, 실제로는 4일 중 3일을 틀렸습니다. 상쇄 때문입니다.
- $MAE = (1 + 1 + 0 + 2) \div 4 = 1.0$. 하루 평균 1도 빗나갑니다.
- $MSE = (1 + 1 + 0 + 4) \div 4 = 1.5$. 목요일의 오차 2가 제곱되어 4가 되면서 MSE를 끌어올렸습니다.

예제 2 R^2 — 게으른 모델과 비교하기

어느 도시의 5년치 연평균기온과 회귀 직선의 예측입니다. R^2 를 구합니다.

	1년차	2년차	3년차	4년차	5년차
실제(°C)	4	6	8	10	12
직선의 예측(°C)	5	6	7	10	12
오차 ²	1	0	1	0	0
(실제 - 평균) ²	16	4	0	4	16

1. 실제 값의 평균 = $(4 + 6 + 8 + 10 + 12) \div 5 = 8$. 게으른 모델은 5년 내내 8만 찍습니다.
2. 게으른 모델의 제곱오차 합 SST = $16 + 4 + 0 + 4 + 16 = 40$.
3. 내 직선의 제곱오차 합 SSE = $1 + 0 + 1 + 0 + 0 = 2$.
4. $R^2 = 1 - (2 \div 40) = 1 - 0.05 = 0.95$. "내 직선은 평균만 찍는 모델이 내는 오차의 95%를 없앴다."

연습 1 오차 표 채우기

영화 4편의 실제 관객 수(만 명)와 내 모델의 예측입니다. 빈칸을 채우고 세 값을 구하세요.

	가	나	다	라
실제(만 명)	30	50	40	60
예측(만 명)	34	46	40	64
오차				
오차				
오차 ²				

(1) 오차의 합 _____ (2) MAE _____ (3) MSE _____

(4) 오차의 합이 작은데도 이 모델을 "거의 완벽하다"고 말할 수 없는 까닭을 한 문장으로.

연습 2 MAE와 MSE의 판정이 같릴 때

두 예측기가 같은 4일을 예측했고 오차만 적어 두었습니다.

	1일	2일	3일	4일
모델 A의 오차	+2	-2	+2	-2
모델 B의 오차	0	0	0	-6

(1) MAE: A _____ B _____ (2) MSE: A _____ B _____

(3) MAE로 고르면 _____, MSE로 고르면 _____ 이 좋은 모델입니다.

(4) 판정이 같린 까닭을 "제공"이라는 낱말을 써서 한 문장으로.

연습 3 R^2 계산

4개 점의 실제 값과 직선의 예측입니다. 표를 채우고 R^2 를 구하세요.

	1	2	3	4	합
실제	10	20	30	40	
예측	12	18	32	38	
오차 ²					SSE =
(실제 - 평균) ²					SST =

(1) 평균 _____ (2) SST _____ (3) SSE _____ (4) $R^2 = 1 - (SSE \div SST) =$

(5) 말로 옮기기: "내 직선은 평균만 찍는 모델이 내는 오차의 _____ %를 없앴다."

문제 1. 5년치 실제 기온 5, 7, 9, 11, 13과 예측 6, 8, 8, 10, 13. 평균·SST·SSE· R^2 를 구하세요.

문제 2. 영화 3편의 실제 관객(만 명) 20, 40, 90과 예측 30, 40, 80. R^2 를 구하고, 같은 모델을 "관객 수가 서로 비슷한 3편"에 썼다면 SST와 R^2 가 어떻게 되는지 쓰세요.

문제 3. 실제 값 10, 12, 14에 대해 세 번 모두 16으로 예측하는 엉터리 모델이 있습니다. SST·SSE· R^2 를 구하고, R^2 가 음수라는 것이 무슨 뜻인지 한 문장으로 쓰세요.

문제 4. 계산 없이 답하기. 데이터의 평균값만 매번 찍는 모델의 R^2 는 얼마이며, 그 까닭은 무엇입니까?

문제 5. 어느 모델의 MSE가 0.4이고 데이터가 5개입니다. 제곱오차의 합(SSE)은 얼마입니까? 평균 모델의 제곱오차 합이 40이라면 R^2 는?

기온 예측기의 R^2 는 관측일 필터를 켜면 0.70, 끄면 0.39였습니다. 영화 다중 회귀의 테스트 R^2 는 개봉 전 변수 3종으로 0.24, 첫 주 관객 수를 더하면 0.90이었습니다.

(1) 필터를 끄면 R^2 가 떨어지는 까닭을 1953년(겨울 31일만 관측)과 연습 2에서 확인한 "제곱"의 성질로 설명하세요.

(2) 0.24는 "나쁜 모델"의 증거입니까? R^2 의 뜻("평균 모델 대비")으로 다시 읽어 보세요.

(3) 0.90은 "좋은 모델"의 증거입니까? 첫 주 관객 수라는 변수의 시점을 근거로 답하세요.

(4) " R^2 가 높은 모델 = 미래를 잘 맞히는 모델"이라는 주장의 허점을 2100년 슬라이더를 예로 쓰세요.

분류 모델의 평가 — 혼동행렬과 세 지표

개념

네 칸과 세 나눗셈

예측: 성공

예측: 실패

실제: 성공

실제: 실패

TP 맞다고 했는데 정말 맞음	FN 아니라고 했는데 사실 맞음
FP 맞다고 했는데 틀림	TN 아니라고 했는데 정말 아님

① **정확도** = $(TP + TN) \div \text{전체}$
네 칸 전체 중 초록 두 칸

② **정밀도** = $TP \div (TP + FP)$
"성공"이라 말한 것(왼쪽 세로 열) 중에서

③ **재현율** = $TP \div (TP + FN)$
실제 성공작(위쪽 가로 행) 중에서

분자는 셋 다 TP에서 출발한다. 셋을 가르는 것은 분모다.

정확도

$(TP + TN) \div \text{전체}$

전체 중 얼마나 맞혔나. 라벨이 치우치면 홀로는 부적절(교과서 139쪽).

정밀도

$TP \div (TP + FP)$

"성공"이라 말한 것 중 진짜 성공. 잘못 걸러 내면 안 되는 문제(스팸 필터)의 지표.

재현율

$TP \div (TP + FN)$

실제 성공작 중 잡아낸 비율. 하나도 놓치면 안 되는 문제(감염병 검사)의 지표.

다수결 기준선

$\text{다수 클래스 수} \div \text{전체}$

아무 계산 없이 전부 다수로 찍는 모델의 정확도. 분류기가 넘어야 할 출발선.

예제 네 칸 채우고 세 지표 구하기

영화 50편(실제 성공 10편, 실패 40편)을 분류했습니다. 성공 10편 중 7편을 성공으로 맞췄고, 실패 40편 중 5편을 성공이라 잘못 예측했습니다.

	예측: 성공	예측: 실패	합계
실제: 성공	TP 7	FN 3	10
실제: 실패	FP 5	TN 35	40
합계	12	38	50

1. $FN = 10 - 7 = 3$ (놓친 성공작), $TN = 40 - 5 = 35$. 합계 행과 열이 맞는지 확인합니다.
2. 정확도 = $(7 + 35) \div 50 = \mathbf{0.84}$
3. 정밀도 = $7 \div (7 + 5) = 7 \div 12 \approx \mathbf{0.58}$. 분모는 "성공이라 예측한 것" 12편입니다.
4. 재현율 = $7 \div (7 + 3) = 7 \div 10 = \mathbf{0.70}$. 분모는 "실제 성공작" 10편입니다.
5. 기준선: 전부 "실패"로 찍으면 $40 \div 50 = \mathbf{0.80}$. 내 분류기는 기준선을 4%p 넘었고, 성공작 열 편 중 일곱 편을 잡았습니다.

연습 1 스팸 필터

메일 30통(스팸 6, 정상 24)을 분류했습니다. 스팸 6통 중 4통을 스팸으로 맞췄고, 정상 24통 중 3통을 스팸이라 잘못 분류했습니다. ("스팸"이 양성입니다.)

	예측: 스팸	예측: 정상	합계
실제: 스팸			6
실제: 정상			24

- (1) 정확도 _____ (2) 정밀도 _____ (3) 재현율 _____ (4) "전부 정상" 기준선의 정확도 _____
- (5) 정밀도가 1이 아니어서 벌어지는 일을 한 문장으로. ("스팸함을 열어 보니 ...")

연습 2 두 모델, 상황이 승자를 정한다

감염병 검사 40명(감염 8, 정상 32)에 대한 두 모델입니다.

모델 A	예측: 감염	예측: 정상
실제: 감염	8	0
실제: 정상	8	24

모델 B	예측: 감염	예측: 정상
실제: 감염	4	4
실제: 정상	0	32

	정확도	정밀도	재현율
모델 A			
모델 B			

(1) 표를 채우세요. (2) 정확도가 높은 모델은 _____ 입니다. (3) 감염자를 한 명도 놓치면 안 되는 검사라면 어느 모델을 골라야 합니까? 지표를 근거로 쓰세요.

스스로 풀기 2부

문제 1. 영화 100편(성공 15, 실패 85). 분류기 결과 TP 9, FN 6, FP 6, TN 79. 정확도·정밀도·재현율과 "전부 실패" 기준선을 구하고, 이 분류기가 기준선을 몇 %p 넘었는지 쓰세요.

문제 2. 시험 200명 중 부정행위자가 10명입니다. 아무 계산 없이 전원을 "정상"으로 판정하는 모델의 정확도와 부정행위 재현율을 구하고, 이 두 값의 공존이 무엇을 보여 주는지 한 문장으로 쓰세요.

문제 3. 문턱값을 움직이면. 로지스틱 회귀가 영화 6편에 낸 성공 확률과 실제입니다.

확률	0.9	0.7	0.6	0.45	0.4	0.1
실제	성공	실패	성공	실패	성공	실패

(1) 문턱 0.5: 혼동행렬을 만들고 정밀도·재현율을 구하세요. (2) 문턱 0.35로 낮추면? (3) 문턱을 낮추자 재현율은 (올랐다/내렸다), 정밀도는 (올랐다/내렸다). 성공작을 놓치기 싫은 배급사 발굴팀과 "성공" 예측에 돈을 거는 투자자는 각각 문턱을 어느 쪽으로 옮기고 싶어 합니까?

문제 4. 반칙 판정. "개봉 전에 흥행 성공을 예측하는 모델"의 입력 변수 후보입니다. 누수(반칙)에 해당하는 것을 모두 고르고 까닭을 쓰세요. (가) 장르 (나) 개봉 시기(성수기 여부) (다) 개봉 첫 주 관객 수 (라) 감독의 전작 흥행 성적 (마) 최종 누적 관객 수 (바) 개봉일 스크린 수

수업 실측 게으른 모델이 이긴다

영화 216편 중 성공작(기준 100만 명)은 23편입니다. 개봉 전 변수 3종으로 학습한 로지스틱 회귀는 정확도 0.877, 성공 재현율 0.00. 의사결정트리(깊이 3)는 0.908, 재현율 0.29. 첫 주 관객 수를 넣은 로지스틱 회귀는 0.985였습니다.

(1) 전부 "실패"로 찍는 기준선의 정확도를 계산하세요. _____

(2) 로지스틱 회귀의 0.877을 "꽤 좋은 모델"이라 말할 수 없는 까닭을 두 가지 쓰세요.

(3) 의사결정트리는 기준선을 넘었습니다. 그런데도 "성공작 열 편 중 일곱 편은 놓친다"고 말할 수 있는 근거는 어느 지표입니까?

(4) 0.985를 성능 개선이라 부를 수 없는 까닭을 "변수의 시점"으로 쓰세요.

연관 분석 — 지지도 · 신뢰도 · 향상도

개념 나눗셈 세 번, 분모가 다르다

지지도

함께 나온 횟수 ÷ 전체

이 조합, 다룰 만큼 자주 나오는가.

신뢰도

함께 나온 횟수 ÷ A가 나온 횟수

A가 나오면 B도 나오는가. 방향이 있다.

향상도

신뢰도 ÷ (B가 나온 횟수 ÷ 전체)


우연히 겹칠 확률보다 나은가. 1이면 우연과 같음.

최소 지지도

예: 동시 5회 이상

한 번의 우연을 먼저 거르는 문턱.

전체 N일



$$\text{지지도} = AB \div N$$

$$\text{신뢰도} = AB \div A$$

$$\text{향상도} = (AB \div A) \div (B \div N)$$

B가 원래 자주 나오면($B \div N$ 이 크면) 향상도는 1로 내려온다

예제 카레와 단무지

급식 20일 가운데 카레 5일, 단무지 8일, 둘이 함께 나온 날 4일. 규칙 "카레 → 단무지"를 평가합니다.

1. 지지도 = $4 \div 20 = 0.20$. 전체의 20%에서 이 조합이 나왔습니다.
2. 신뢰도 = $4 \div 5 = 0.80$. 카레가 나온 날의 80%에 단무지가 따라왔습니다.
3. 단무지의 기본 등장률 = $8 \div 20 = 0.40$.
4. 향상도 = $0.80 \div 0.40 = 2.0$. 카레가 나온 날 단무지가 나올 확률은 아무 날의 2배입니다. 우연 이상의 짝입니다.

연습 1 높은 신뢰도가 아무 정보도 아닐 때

매점 50일 기록에서 컵라면 20일, 삼각김밥 25일, 둘 다 산 날 10일. "컵라면 → 삼각김밥"을 평가하세요.

(1) 지지도 _____ (2) 신뢰도 _____ (3) 삼각김밥의 기본 등장률 _____ (4) 향상도 _____

(5) "컵라면을 산 날의 절반은 삼각김밥도 산다"는 말은 사실입니다. 그런데 이 규칙으로 묶음 할인을 하면 안 되는 까닭은?

연습 2 방향을 바꾸면

급식 20일에서 짜장밥 4일, 단무지 10일, 함께 나온 날 4일.

(1) "짜장밥 → 단무지": 신뢰도 _____ 향상도 _____

(2) "단무지 → 짜장밥": 신뢰도 _____ 향상도 _____

(3) 신뢰도는 방향에 따라 (같다/다르다), 향상도는 (같다/다르다). 계산식을 보고 까닭을 한 문장으로.

(4) "단무지가 나온 날은 짜장밥을 기대해도 되나?"에 답하는 지표는 어느 쪽 신뢰도입니까?

스스로 풀기 3부

문제 1. 급식 30일에서 떡볶이 6일, 튀김 9일, 함께 나온 날 6일. "떡볶이 → 튀김"의 지지도·신뢰도·향상도를 구하고 급식실의 언어로 한 문장을 쓰세요.

문제 2. 100일 동안 우유 90일, 빵 30일, 함께 나온 날 27일. "빵 → 우유"의 신뢰도와 향상도를 구하고, 이 규칙이 12차시의 어느 규칙과 같은 구조인지 쓰세요.

문제 3. 100일 중 딱 하루, 두 메뉴가 함께 나왔고 각자 그날 한 번씩만 등장했습니다. 이 규칙의 신뢰도와 향상도를 구하고, 향상도가 문제 1(약 3.3)보다 30배 큰데도 믿으면 안 되는 까닭과 그래서 무엇을 먼저 정하는지 쓰세요.

.....

.....

문제 4. 판단 문제. 매점 사장님이 묶음 할인을 하나만 할 수 있습니다.

규칙	지지도	신뢰도	향상도
R1: 삼각김밥 → 컵라면	0.30	0.60	1.05
R2: 떡볶이 → 모차렐라스틱	0.04	0.80	6.0

(1) 각 규칙에 할인을 걸었을 때 기대되는 것과 걱정되는 것을 한 가지씩. (2) 목표가 "떡볶이 손님의 객단가 올리 기"라면? "전체 매출 규모 키우기"라면? 정답보다 근거가 점수입니다.

.....

.....

수업 실측 김치의 배신

당국고 중식 154일에서 제육볶음 9일, 배추김치 86일, 함께 나온 날 5일. 순대국 5일, 석박지 17일, 순대국이 나 온 5일 모두 석박지 동행. 배추김치 86일과 깍두기 26일은 함께 나온 날 0일.

(1) "제육볶음 → 배추김치": 신뢰도 $5 \div 9 \approx$ _____ 기본 등장률 $86 \div 154 \approx$ _____ 향상도 $\approx$ _____

(2) "순대국 → 석박지": 신뢰도 _____ 향상도 $1.00 \div (17 \div 154) \approx$ _____ 역방향 "석박지 → 순 대국"의 신뢰도 $5 \div 17 \approx$ _____

(3) 배추김치와 깍두기가 우연으로 나온다면 함께 나올 것으로 기대되는 날수 $86 \times 26 \div 154 \approx$ _____ 일. 실제로는 0일. 이 "음의 연관"에서 급식실의 운영 규칙을 역추론하세요.

.....

.....

(4) 향상도 9.1은 "순대국이 석박지를 나오게 만든다"는 인과의 증명입니까?

.....

.....

군집 평가 — 거리 · 정규화 · 실루엣

개념 군집에는 정답표가 없다

회귀·분류·연관에는 비교할 정답이나 기준(평균 모델, 다수결 기준선, 우연)이 있었습니다. 군집에는 정답표(라벨)가 없으므로, 평가도 "얼마나 맞혔나"가 아니라 "묶음이 얼마나 조밀하고 서로 떨어져 있나"(실루엣)와 "묶음이 말이 되나"(해석)의 두 축으로 합니다. 그리고 그 전에 거리 계산 자체가 공정한지(정규화)부터 확인합니다.

거리

$$\sqrt{(\text{가로 차}^2 + \text{세로 차}^2)}$$

두 데이터가 얼마나 비슷한가를 속성 값의 차이로 잰다. k-평균은 이 거리로 묶는다.

정규화

값 ÷ 그 속성의 최댓값 (한 방법)

단위가 큰 속성이 거리를 독차지하지 않도록 범위를 맞춘다.

실루엣

-1 ~ +1

군집 안은 조밀하고 군집 사이는 멀수록 1에 가깝다. 의미는 재지 못한다.

해석

이름은 사람이 붙인다

묶음별 평균 스탯을 읽고 유형 이름을 짓는다. k에 정답은 없다.

예제 정규화 없이는 거리가 한쪽 말만 듣는다

세 타자의 두 스탯입니다. 누가 누구와 가까운지 거리를 계산합니다.

선수	홈런	도루
A	30	5
B	10	40
C	28	8

1. A와 C의 거리 = $\sqrt{((30-28)^2 + (5-8)^2)} = \sqrt{(4 + 9)} = \sqrt{13} \approx 3.6$
2. A와 B의 거리 = $\sqrt{((30-10)^2 + (5-40)^2)} = \sqrt{(400 + 1225)} = \sqrt{1625} \approx 40.3$
3. A는 C와 가깝습니다(둘 다 거포형). 이 예에서는 두 스탯의 단위가 비슷해 문제가 없지만, 도루 대신 타율(0.3 안팎)이 들어오면 사정이 달라집니다. 타율 차이는 아무리 커도 0.1 정도라 제공하면 0.01이 되어, 홈런 차이 2의 제공 4 앞에서 사라집니다. 거리가 홈런 말만 듣게 됩니다. 정규화가 필요한 까닭입니다.

연습 정규화한 뒤 다시 재기

세 타자의 홈런과 타율입니다. 각 속성을 그 열의 최댓값으로 나눠 0~1 범위로 맞추 뒤 거리를 비교하세요.

선수	홈런	타율	홈런 ÷ 30	타율 ÷ 0.340
A	30	0.260		
B	12	0.340		
C	27	0.335		

- (1) 정규화 전: A-B 거리와 A-C 거리 중 어느 쪽이 가깝습니까? (홈런 차이만 봐도 답이 나옵니다.) (2) 정규화 후: A-C 거리 _____ B-C 거리 _____ 이제 C는 누구와 더 가깝습니까? (3) 두 답이 다른 까닭을 한 문장으로.

문제 1. 어떤 데이터에서 실루엣 점수가 $k=2$ 일 때 0.41, $k=3$ 일 때 0.40, $k=5$ 일 때 0.22입니다. 점수만 보면 k 는 몇입니까? 그런데 $k=3$ 의 세 묶음에 "공격형·수비형·균형형"이라는 이름이 자연스럽게 붙고 $k=2$ 는 "잘하는 선수·나머지"로만 나뉜다면, 어느 k 를 고르겠습니까? 근거를 쓰세요.

문제 2. 지도학습(회귀·분류)의 평가와 군집의 평가가 근본적으로 다른 점을 "정답"이라는 낱말을 써서 두 문장으로 쓰세요.

수업 실측 점수는 $k=2$, 해석은 $k=3$

2025 시즌 KBO 규정타석 타자 43명의 군집에서 실루엣 점수는 $k=2$ 가 0.268, $k=3$ 이 0.262였습니다. 정규화 없이 돌리면 삼진과 홈런이 군집을 지배했습니다. $k=3$ 의 세 묶음은 거포형 9명(홈런 27.6·장타율 0.542), 발 빠른 교타형 18명(도루 17.1), 중장거리형 16명(홈런 16.8·삼진 108.6)이었습니다.

(1) 정규화 없이 돌리면 삼진이 군집을 지배하는 까닭을 이 부의 예제와 연결해 쓰세요.

(2) 점수는 $k=2$ 가 높는데 수업에서는 $k=3$ 을 골랐습니다. 이 선택이 "점수를 무시한 것"이 아닌 까닭을 쓰세요.

(3) "거포형·교타형·중장거리형"이라는 이름은 누가, 무엇을 보고 붙였습니까?

✅ 활동지를 마치며 — 네 부를 관통하는 한 가지 습관

회귀의 R^2 는 평균 모델과, 분류의 정확도는 다수결 기준선과, 연관의 향상도는 우연과, 군집의 실루엣은 해석과 나란히 놓고 읽었습니다. 큰 숫자를 만나면 비교할 상대부터 세우는 것, 이것이 네 부에서 이름만 바뀌 반복된 습관입니다. AI가 보여 주는 점수를 손으로 다시 만들 수 있는 사람만이 그 점수를 의심할 수 있습니다.