

『데이터 과학』 이론 정리

교과서 『데이터 과학』의 핵심 정의를 원문 그대로 인용하고(쪽수 표기), 우리 교재에서 추가로 배운 내용(API, 평가 손계산, 새 모델, SQL)을 교과서 순서에 맞춰 정리했습니다. 시험 범위는 공통 수업 1~14차시 전체입니다. 계산 문항은 별도 문서 평가 손계산 활동지에서 손으로 연습합니다.

이 문서로 공부하는 순서

① 정의 상자의 교과서 문장을 소리 내어 읽습니다. ② 바로 아래 풀이와 "우리 실습 장면"을 읽고, 그 정의가 어느 수업의 어떤 장면이었는지 떠올립니다. ③ 절 끝의 확인 문제를 풀고 부록 C의 정답과 비교합니다. ④ 부록 A의 실측 수치 표에서 숫자마다 "어느 장면의 숫자인가"를 말로 설명할 수 있으면 준비가 끝난 것입니다.

차례

- | | |
|---------------------------|------------------------------------|
| 1. I-1 데이터 과학과 문제 해결의 6단계 | 11. III-2 회귀 |
| 2. I-2 데이터의 종류 | 12. III-3 회귀 모델의 평가 ★ |
| 3. I-3 데이터베이스 | 13. III-4 분류 |
| 4. I-3 보충 SQL 기초 | 14. III-5 분류 모델의 평가 ★ |
| 5. I-4 데이터 윤리 | 15. III-6 군집 |
| 6. II-1 데이터 수집과 API | 16. III-7 연관 분석 ★ |
| 7. II-2 데이터 탐색과 전처리 | 17. 보충 모델 도감 — kNN·랜덤 포레스트·XGBoost |
| 8. II-3 시각화 | 18. 부록 A 실측 수치 한 장 |
| 9. II-4 상관과 인과 | 19. 부록 B 핵심 용어 |
| 10. III-1 기계학습과 모델 평가의 원칙 | 20. 부록 C 확인 문제 정답 |

1. 데이터 과학과 문제 해결의 6단계 (1차시)

교과서의 정의 『데이터 과학』 11쪽

"데이터 과학은 데이터를 기반으로 실제 현상을 이해하고 분석하기 위해 통계, 데이터 분석, 기계학습 및 관련 방법을 통합하는 학문 분야이다."


"데이터를 수집·분석하여 의사 결정을 내리는 것을 '데이터 기반 의사 결정'이라고 한다."

→ 데이터 과학은 한 가지 기술이 아니라 여러 방법을 합쳐 쓰는 학문입니다. 데이터 기반 의사 결정은 기억이나 느낌만으로 정하는 결정과 구별되는 결정 방식입니다. 선택 과목을 고를 때 이전 학기 성적, 흥미, 진로 관련성을 함께 보는 일이 그 예입니다.

문제 해결의 6단계

교과서의 정의 14쪽

"데이터 과학의 문제 해결 과정은 크게 문제 정의하기, 데이터 수집하기, 전처리 및 탐색하기, 모델링하기, 모델 평가하기, 모델 활용하기의 6단계로 구분할 수 있다. 그러나 6개의 단계를 순서대로 모두 거쳐야 하는 것은 아니다."



단계	하는 일	우리 수업의 장면
문제 정의	무엇이 궁금한지 데이터로 답할 수 있는 질문으로 바꾼다. 전체 계획을 세운다	"서울은 정말 더워지고 있을까", "영화 흥행을 미리 맞힐 수 있을까"
데이터 수집	필요한 데이터를 내려받거나 API로 받아 온다	기온 CSV 내려받기, 영화·급식 API 호출
전처리·탐색	결측·이상치를 확인해 처리하고, 요약 통계와 그래프로 데이터의 생김새를 본다	1953년 반쪽 값 걸러 내기, 그래프 도감
모델링	데이터에서 패턴을 찾아 모델(회귀·분류·군집·연관)을 만든다	기온 직선, 흥행 분류기, 선수 군집, 급식 규칙
모델 평가	학습에 쓰지 않은 데이터로 성능을 재고 한계를 확인한다	R^2 , 혼동행렬, 실루엣, 향상도 손계산
모델 활용	결과를 공유하고 의사 결정에 쓴다	스트림릿 앱 배포, 갤러리 공유

여섯 단계는 고정된 절차가 아닙니다. 평가 결과가 만족스럽지 않으면 데이터 수집이나 문제 정의로 되돌아갈 수 있고, 어떤 단계는 건너뛸 수도 있습니다. 그리고 여섯 단계 모두에 사람의 판단이 들어 있습니다. 무엇을 썰지, 어떤 값을 버릴지, 어떤 모델을 쓸지, 결과를 얼마나 믿을지는 컴퓨터가 정해 주지 않습니다.

데이터로 답할 수 있는 질문

좋은 질문의 조건은 세 가지입니다. **측정 가능**해야 하고, **데이터로 답할 수 있어야** 하며, **범위가 명확**해야 합니다. "우정은 성적보다 소중한가"는 썰 대상이 없는 가치 판단이라 데이터로 답할 수 없습니다. "지난 100여 년간 서울의 연평균 기온은 어떤 추세로 변해 왔는가"는 기온 데이터만으로 답할 수 있는 질문입니다.

우리 실습 장면

서울 일별 평균기온의 히스토그램은 산 하나가 아니라 봉우리가 둘입니다. 0°C 부근에 하나, 20°C를 넘는 곳에 하나가 있습니다. 겨울과 여름에 하루하루의 기온이 몰려 있기 때문입니다. 평균 하나로는 보이지 않던 데이터의 생김새가 그래프에서 보입니다. 이것이 탐색적 데이터 분석의 출발점입니다.

확인 문제

- 1 6단계 가운데 "학습에 쓰지 않은 데이터로 성능을 잴다"에 해당하는 단계는 무엇입니까?
- 2 "6개의 단계를 순서대로 모두 거쳐야 하는 것은 아니다"의 뜻을 예를 들어 설명하시오.
- 3 다음 중 기온 데이터만으로 답할 수 있는 질문을 고르시오. ㉠ 서울의 겨울은 언제부터 낭만적으로 느껴졌는가 ㉡ 최근 20년 서울 연평균기온의 기울기는 100년당 몇 도인가 ㉢ 서울시는 어떤 기후 정책을 세워야 하는가

1. 데이터 과학의 이해

2. 데이터의 종류 (2·5차시)

교과서의 정의 19·20쪽

"정형 데이터(structured data)는 데이터의 속성이나 구조가 명확하고 체계화된 데이터를 말한다." (19쪽)

"비정형 데이터(unstructured data)는 구조를 명확하게 정의하기 어려운 데이터를 말한다." (20쪽)

"반정형 데이터는 일부분이 정형화된 데이터로, 구조가 존재하지만 구조를 바꿀 수도 있는 유연한 형태의 데이터를 말한다." (20쪽)

"대표적인 반정형 데이터로는 XML(eXtensible Markup Language)과 JSON(JavaScript Object Notation)이 있다." (20쪽)

종류	생김새	우리 실습의 예	분석 전에 할 일
정형	행과 열이 반듯한 표	기온 CSV(seoul.csv), 영화 216 편 요약표	바로 표로 읽는다
반정형	구조는 있지만 표는 아님. 라벨과 값 의 짝, 상자 안의 상자	영화 API·급식 API의 JSON 응답	필요한 값을 꺼내 표로 바 꾼다
비정형	구조를 정의하기 어려움	급식 사진, 영화 포스터, 리뷰 글	숫자로 표현하는 별도 처 리가 필요하다

표로 된 데이터는 행 하나가 관측 대상 하나(하루, 영화 한 편, 선수 한 명)이고, 열 하나가 속성 하나(날짜, 관객 수, 홈런)입니다. 교과서는 이 속성 안에 데이터의 잠재적 가치가 들어 있다고 봅니다. 같은 급식 데이터라도 어떤 속성(메뉴, 알레르기 번호, 칼로리)을 쓰느냐에 따라 답할 수 있는 질문이 달라집니다.

교과서의 정의 20쪽

"이러한 반정형 데이터는 데이터 구조를 쉽게 변경할 수 있고, 필요한 경우 표 형태로도 쉽게 변환할 수 있어 데이터 공유에 많이 활용된다."

→ JSON은 {"라벨": 값} 짝의 상자입니다. 상자 하나가 표의 행 하나로 바뀝니다. 박스오피스와 급식, 두 API에서 두 번 확인했습니다.

우리 실습 장면 — 숫자가 글자로 온다

영화 API의 관객 수는 "164393"처럼 따옴표가 붙은 글자로 옵니다. 글자인 채로 정렬하면 사전순이 되어 "9"가 "164393"보다 뒤에 섭니다. 계산하기 전에 숫자로 바뀌어야 합니다. 반정형 데이터를 표로 바꿀 때 가장 자주 부딪히는 문제입니다.

확인 문제

- 1 급식 식단표, 급식 사진, 급식 API의 JSON 응답을 정형·반정형·비정형으로 각각 구분하시오.
- 2 JSON이 데이터 공유에 많이 쓰이는 까닭을 교과서 20쪽의 문장을 바탕으로 두 가지 쓰시오.

I. 데이터 과학의 이해

3. 데이터베이스 (13차시)

교과서의 정의 25~27쪽

"데이터셋(dataset)이란 하나의 주제에 대한 여러 데이터들이 모인 집합(set)을 말한다." (25쪽)

"데이터베이스(database)는 여러 사람이 공유하여 사용하기 위해 통합 관리되는 데이터의 집합으로, 데이터베이스 시스템을 사용하면 대규모의 데이터를 효율적으로 저장하고 검색하며, 업데이트하고 관리할 수 있다." (26쪽)

"데이터베이스에는 여러 종류의 데이터셋이 들어가는데, 이때 각각의 데이터셋은 표 형태로 저장되며 이를 테이블(table)이라고 한다." (27쪽)

→ CSV 파일 하나가 데이터셋입니다. 그것을 여럿이 공유하도록 통합 관리하는 것이 데이터베이스(우리 학급 수파베이스 프로젝트)이고, 그 안의 표 하나하나가 테이블(방명록 표, 갤러리 표)입니다.

파일로 부족해지는 세 순간

정의의 핵심은 "여러 사람이 공유하여"입니다. 혼자 분석할 때는 파일이면 충분합니다. 여럿이 함께 쓰는 순간 파일은 세 가지 한계에 부딪힙니다.

부족해지는 순간	CSV 파일이라면	데이터베이스라면
동시에 쓰기	두 사람이 같은 파일을 고쳐 저장하면 나중에 저장한 쪽이 앞 사람의 작업을 덮는다	여러 사람의 기록이 각각 한 행으로 안전하게 들어간다
계속 쌓기	새 글이 올 때마다 파일을 열어 고치고 다시 저장해야 한다	새 데이터가 자동으로 누적된다
골라 읽기	전체를 내려받아 눈으로 찾아야 한다	조건에 맞는 것만 즉시 검색해 가져온다

데이터베이스의 이점 네 가지와 네 가지 동작

교과서 26쪽은 데이터베이스의 이점을 네 가지로 정리합니다.

이점	뜻	방명록 실습에서
편리한 버전 관리	누가 언제 무엇을 고쳤는지 기록이 남는다	작성 시각(created_at) 열이 자동으로 채워진다
데이터 무결성 유지	잘못된 값이 들어오지 않도록 제약을 건다	빈 칸으로 제출하면 저장하지 않는 ③ 개선
데이터 보안 강화	사용자마다 할 수 있는 일(권한)을 나눈다	비밀번호가 맞을 때만 고치고 지운다
체계적인 데이터 관리	조건으로 검색하고 정렬한다	최신순으로 정렬해 보여 주기

데이터베이스가 하는 일은 결국 네 동작으로 요약됩니다(29쪽). **생성(Create), 읽기(Read), 갱신(Update), 삭제(Delete)**, 앞 글자를 따서 CRUD라고 부릅니다. 방명록 기본 실습이 생성과 읽기, 도전 과제가 갱신과 삭제였습니다. 갱신과 삭제는 데이터를 바꾸는 동작이라 "누가 할 수 있는가"라는 권한 문제가 반드시 따라옵니다.

테이블 설계 — 속성명·데이터형·조건

교과서 31쪽 탐구활동은 쇼핑몰 데이터베이스의 테이블(사용자·제품·장바구니)을 설계합니다. 테이블을 설계한다는 것은 얼마나 **속성명**(무엇을 담는가), **데이터형**(글자인가 숫자인가 날짜인가), **조건**(비워도 되는가, 중복되면 안 되는가)을 정하는 일입니다. 우리 방명록 테이블을 같은 양식으로 적으면 다음과 같습니다.

속성명	설명	데이터형	조건
id	글 번호	정수	자동 증가, 중복 불가(기본 키)
name	작성자 이름	문자열	비워 둘 수 없음
message	한 줄 소감	문자열	비워 둘 수 없음
password	네 자리 비밀번호	문자열	고치기·지우기 확인용
created_at	작성 시각	날짜·시각	저장 시각이 자동으로 들어감

기본 키(primary key)는 행 하나를 유일하게 가리키는 열입니다. 같은 이름의 사람이 두 번 글을 남겨도 id가 다르므로 두 행을 구별할 수 있습니다. 갱신과 삭제가 "7번 글"처럼 특정 행 하나를 정확히 겨냥할 수 있는 것도 기본 키 덕분입니다.

우리 실습 장면 — "내 파일"에서 "우리의 저장소"로

방명록에 글을 남기고 새로고침해도 글이 남아 있습니다. 친구의 컴퓨터에서 열어도 같은 글이 보입니다. 두 사람이 거의 동시에 글을 남겨도 한쪽이 사라지지 않고 각각 한 행으로 쌓입니다. 한 학기 내내 작품을 올리고 피드백을 남긴 갤러리도 같은 도구(수파베이스)였습니다.

확인 문제

- 1 데이터셋·데이터베이스·테이블을 우리 실습의 예(급식 CSV 파일, 학급 수파베이스 프로젝트, 방명록 표)에 각각 대응하시오.
- 2 모둠 과제 자료를 CSV 파일로 메신저에서 주고받는 방식과 비교해 데이터베이스의 이점을 두 가지 서술하시오.
- 3 방명록의 "고치기·지우기" 기능에 비밀번호 확인이 필요한 까닭을 데이터베이스의 이점 네 가지 중 하나와 연결해 설명하시오.

1. 데이터 과학의 이해 · 교재 보충

3-보충. SQL 기초 — 테이블에 말을 거는 언어

교재에서 추가한 내용

교과서는 데이터베이스의 개념과 설계까지 다룹니다. 우리 교재는 여기에 SQL 기초를 보탭니다. 수파베이스 화면의 SQL 편집기와 AI가 짜 준 코드 안에 이 문장들이 그대로 들어 있기 때문입니다. 문장을 외우는 것이 목적이 아니라, 네 동작(CRUD)이 어떤 문장으로 표현되는지 읽을 수 있으면 됩니다.

SQL(Structured Query Language, 구조화 질의 언어)은 테이블에 데이터를 넣고, 꺼내고, 고치고, 지우라고 지시하는 언어입니다. 수파베이스처럼 표(테이블) 형태로 데이터를 관리하는 데이터베이스를 **관계형 데이터베이스**라고 하며, 관계형 데이터베이스는 대부분 SQL로 다룹니다. SQL 문장은 영어 문장과 비슷하게 읽힙니다. 대문자로 쓴 낱말이 명령어이고, 나머지가 테이블 이름과 열 이름입니다.

읽기(Read) — SELECT

가장 자주 쓰는 문장입니다. 어느 테이블(FROM)에서 어느 열(SELECT)을 가져올지 말하고, 필요하면 조건(WHERE)과 정렬(ORDER BY)을 덧붙입니다.

-- 방명록의 이름·소감·작성 시각을 최신순으로 가져온다

```
SELECT name, message, created_at
FROM guestbook
ORDER BY created_at DESC;
```

-- 모든 열(*)을 가져오되, 이름이 '민수'인 글만

```
SELECT * FROM guestbook WHERE name = '민수';
```

날말	뜻	비유
SELECT	가져올 열을 고른다. *는 모든 열	"이름과 소감 열만 보여 줘"
FROM	어느 테이블에서 가져올지	"방명록 표에서"
WHERE	조건에 맞는 행만 남긴다	"이름이 민수인 것만"
ORDER BY	정렬 기준. DESC는 내림차순, ASC는 오름차순	"최신 글부터"

세 번째 한계였던 "골라 읽기"가 바로 WHERE입니다. 파일이라면 전체를 내려받아 눈으로 찾아야 했던 일을, 데이터베이스는 조건 한 줄로 해냅니다.

생성·갱신·삭제 — INSERT, UPDATE, DELETE

-- 생성(C): 새 글 한 줄을 넣는다. id와 created_at은 자동으로 채워진다

```
INSERT INTO guestbook (name, message, password)
VALUES ('민수', '방명록이 생겨서 신기해요', '1234');
```

-- 갱신(U): 7번 글의 소감을 고친다

```
UPDATE guestbook SET message = '정말 신기해요' WHERE id = 7;
```

-- 삭제(D): 7번 글을 지운다

```
DELETE FROM guestbook WHERE id = 7;
```

⚠ WHERE가 없는 UPDATE·DELETE

UPDATE와 DELETE에서 WHERE를 빼면 테이블의 모든 행이 바뀌거나 지워집니다. 기본 키(id)로 행 하나를 정확히 가리키는 습관이 중요한 까닭입니다. 실제 서비스가 갱신·삭제 권한을 엄격히 나누는 것(데이터 보안 강화)도 같은 이유입니다.

테이블 만들기 — CREATE TABLE

교과서 31쪽의 설계표(속성명·데이터형·조건)는 그대로 SQL 문장이 됩니다. 선생님이 학급 공용 프로젝트에 방명록 테이블을 만들 때 실행한 문장과 같은 구조입니다.

```
CREATE TABLE guestbook (  
  -- 정수 · 자동 증가 · 기본 키  
  id          bigint PRIMARY KEY GENERATED ALWAYS AS IDENTITY,  
  -- 문자열 · 비워 둘 수 없음  
  name        text NOT NULL,  
  message     text NOT NULL,  
  password    text,  
  -- 날짜·시각 · 저장 시각이 자동으로 들어감  
  created_at  timestampz DEFAULT now()  
);
```

설계표의 항목	SQL에서	예
속성명	열 이름	name, message
데이터형	text(문자열) · integer/bigint(정수) · numeric(소수) · boolean(참/거짓) · timestampz(날짜·시각)	관객 수는 bigint, 타율은 numeric
조건	NOT NULL(비워 둘 수 없음) · PRIMARY KEY(기본 키) · UNIQUE(중복 불가) · DEFAULT(기본값)	이메일은 UNIQUE

SQL과 우리 코드의 대응

AI가 짜 준 방명록 코드는 SQL 문장을 직접 쓰지 않고 파이썬 함수로 같은 뜻을 전합니다. 두 표현은 한 줄씩 대응합니다.

동작	SQL	방명록 코드(파이썬)
읽기	SELECT * FROM guestbook ORDER BY created_at DESC	db.table("guestbook").select("*").order("created_at", desc=True)
생성	INSERT INTO guestbook (name, message, password) VALUES (...)	db.table("guestbook").insert({...})
갱신	UPDATE guestbook SET message = ... WHERE id = 7	db.table("guestbook").update({...}).eq("id", 7)
삭제	DELETE FROM guestbook WHERE id = 7	db.table("guestbook").delete().eq("id", 7)

급식 테이블로 연습 — 세는 일도 SQL이 한다

급식 154일을 meals라는 테이블(열: 날짜, 식사, 메뉴)에 넣어 두었다고 합시다. 연관 분석에서 손으로 세었던 값들은 SQL 한 줄로 셀 수 있습니다.

```
-- 배추김치가 나온 날은 며칠인가 (연관 분석의 "기본 등장률"의 분자)
SELECT COUNT(*) FROM meals WHERE 식사 = '중식' AND 메뉴 LIKE '%배추김치%';

-- 순대국과 석박지가 같은 날 나온 날짜 목록
SELECT 날짜 FROM meals
WHERE 식사 = '중식' AND 메뉴 LIKE '%순대국%' AND 메뉴 LIKE '%석박지%';
```

COUNT(*)는 조건에 맞는 행의 개수를 세고, LIKE '%배추김치%'는 메뉴 문자열 안에 "배추김치"가 들어 있는 행을 찾습니다. 첫 문장의 답이 86, 두 번째 문장의 행 수가 5입니다. 12차시에서 손으로 센 바로 그 수입니다.

묶어서 세기 — GROUP BY와 집계

분석 질문의 대부분은 "무엇별로 얼마나"의 꼴입니다. 영화 216편이 movies 테이블(열: 영화명, 장르, 총관객)에 들어 있다고 합시다. "장르별 평균 관객은 얼마인가"는 GROUP BY 한 줄로 답합니다.

```
-- 장르별로 묶어 편수와 평균 관객을 구하고, 평균이 큰 순으로 상위 5개만
SELECT 장르, COUNT(*) AS 편수, AVG(총관객) AS 평균관객
FROM movies
GROUP BY 장르
ORDER BY 평균관객 DESC
LIMIT 5;
```

날말	뜻
GROUP BY	같은 값끼리 묶는다. "장르별로"
COUNT · SUM · AVG · MAX · MIN	묶음마다 개수 · 합계 · 평균 · 최댓값 · 최솟값을 구한다
AS	결과 열에 붙일 이름
LIMIT	앞에서 몇 행만 가져온다. "상위 10개"

4차시의 도넛(장르별 편수)과 트리맵(장르별 총 관객)이 이 문장 하나의 두 열입니다. 그래프로 그리던 질문을 SQL로 물을 수 있으면, 팀 프로젝트에서 데이터가 표 하나에 다 들어가지 않을 때도 필요한 부분만 골라 올 수 있습니다.

중간고사 예상 문제 — 영양사 선생님의 부탁

이야기

학생회 급식부의 지우와 민수에게 영양사 선생님이 부탁을 하나 합니다. "금요일 급식이 유독 무겁다는 의견이 급식 게시판에 여러 번 올라왔어요. 느낌인지 사실인지 확인하고 싶은데, 한 학기치 식단이 meals 테이블에 들어 있으니 요일별로 열량을 비교해 줄 수 있을까요?" 두 사람은 12차시에 급식 규칙을 찾을 때 썼던 바로 그 데이터를 엽니다. 이번에는 파이썬 대신 SQL 편집기입니다.

속성명	설명	데이터형	예
날짜	급식 날짜	날짜	2025-09-02
월	몇 월인지	정수	9
요일	월~금	문자열	'화'
식사	중식 또는 석식	문자열	'중식'
메뉴	그날 메뉴 전체, 세로막대()로 구분	문자열	'현미밥 근대된장국 제육볶음 배추김치'
칼로리	한 끼 열량(kcal)	소수	887.5

- 1 **[장면 1 · 지우의 문장]** 지우가 먼저 나섭니다. "요일별로(GROUP BY) 평균 열량을 내서(AVG), 높은 요일부터(ORDER BY) 보면 되겠다." 지우가 써야 할 SQL 문장을 완성하시오. 중식만 대상으로 하고, 결과 열의 이름은 요일과 평균칼로리로 하시오.
- 2 **[장면 2 · 민수의 오류]** 옆에서 민수가 "요일마다 급식이 며칠씩 있었는지도 같이 보여 드리자"며 문장을 하나 더 씁니다.

```
SELECT 요일, 날짜 FROM meals WHERE 식사 = '중식' GROUP BY 요일;
```

실행 단추를 누르자 빨간 오류 문장이 뜹니다. 지우가 화면을 보더니 말합니다. "요일로 묶었는데 날짜를 그대로 달라고 하면, 한 칸에 서른 개를 어떻게 넣어?" (가) 지우의 말을 "묶음"이라는 낱말을 써서 오류의 까닭으로 풀어 쓰시오. (나) 민수의 뜻대로 요일별 중식 일수가 나오도록 문장을 고쳐 쓰시오.

이야기의 끝 — 숫자가 나온 뒤에 남는 판단

두 문장을 합쳐 실행하니 이런 표가 나왔습니다(칼로리는 연습용 예시 값입니다). 금요일 30일의 평균이 912kcal로 가장 높고, 화요일 31일의 평균이 852kcal로 가장 낮습니다. 지우는 "금요일이 정말 무겁네요"라고 말하려다 멈춥니다. 60kcal 차이가 "유독 무겁다"고 말할 만큼 큰 차이인지, 금요일에 특식이 몇 번 있었던 것은 아닌지, 표만으로는 알 수 없기 때문입니다. SQL은 세는 일을 대신하지만, 그 수가 무엇을 뜻하는지는 1차시부터 배운 대로 사람이 판단합니다.

요일	일수	평균칼로리
금	30	912.4
수	31	885.1
월	31	870.3
목	31	866.0
화	31	851.7

권한 정책 — 표가 기본적으로 닫혀 있는 까닭

수파베이스의 표는 처음부터 아무나 읽고 쓸 수 있는 것이 아닙니다. 표마다 누가 어떤 동작을 할 수 있는가를 정책으로 정해 둡니다(행 수준 보안, RLS). 정책이 없으면 모든 출입이 막혀 있고, 만들어 둔 정책만 통과합니다. 우리 학급 방명록 표는 선생님이 읽기(SELECT)와 추가(INSERT)를 열어 두었고, 갱신과 삭제는 비밀번호 확인을 거치도록 앱에서 한번 더 막았습니다. 교과서 26쪽의 "데이터 보안 강화"가 실제 도구에서 구현된 모습입니다.

바이브 코딩에서 가장 자주 만나는 DB 오류

"연결은 됐는데 저장이 안 된다"의 첫째 원인은 권한 정책이고, 둘째 원인은 AI가 표 이름이나 열 이름을 지어낸 것입니다. AI는 우리 표가 어떻게 생겼는지 볼 수 없습니다. 오류 문장에 permission, policy, not found, column이 보이면 코드보다 먼저 표 이름·열 이름·권한을 확인합니다.

AI에게 DB를 주문할 때 알려 줄 네 가지

SQL 문장을 직접 쓰지 않더라도, AI가 데이터베이스 코드를 맞게 짜려면 AI가 볼 수 없는 사실을 프롬프트에 적어 주어야 합니다. 방명록 실습의 ① 샘플 프롬프트에 이미 네 가지가 다 들어 있었습니다.

알려 줄 것	왜	프롬프트의 문장
표 이름과 열 이름(필요하면 데이터형)	AI는 표를 볼 수 없다. 이름이 한 글자만 달라도 저장되지 않는다	"표 이름은 guestbook이고 열은 name · message · created_at · password야"
새 표를 만들지 말 것	학급 공용 프로젝트에서는 학생이 표를 만들 권한이 없다	"새 표를 만들지 말고 이 표에 그대로 연결해 줘"
접속 정보는 비밀 금고에	주소와 키가 코드에 박히면 공개 저장소로 새어나간다	"접속 정보는 비밀 금고에 넣어 줘"
무결성 조건	빈 값이나 잘못된 값이 들어가지 않게	"빈 칸으로 제출하면 저장하지 말고 안내 문구를 보여 줘"

팀 프로젝트에서 "설문 응답을 팀 표에 모아 장르별 평균을 보여 줘" 같은 주문을 할 때도 같은 네 가지를 적으면 됩니다. 무엇을 만들지와 표의 생김새는 사람이 말하고, SQL 문장과 코드는 AI가 씁니다. 나온 결과가 맞는지 이 절의 문장을 읽을 수 있는 사람만 확인할 수 있습니다.

심화 — 표와 표를 잇는 열

교과서 31쪽 쇼핑물 설계에서 장바구니 표는 사용자 표의 id와 제품 표의 id를 열로 가집니다. 다른 표의 기본 키를 가리키는 이 열을 **외래 키**라 하고, 두 표를 이 열로 이어 붙이는 문장이 JOIN입니다. 같은 정보를 두 표에 중복해서 적지 않아도 되는 것이 데이터베이스가 표를 여러 개로 나누는 까닭입니다.

```
-- 장바구니에 담긴 제품의 이름과 수량을, 장바구니 표와 제품 표를 제품 id로 이어서 가져온다
SELECT 사용자id, 제품.제품명, 장바구니.수량
FROM 장바구니
JOIN 제품 ON 장바구니.제품id = 제품.id;
```

지필 범위에서는 외래 키가 "표와 표를 잇는 열"이라는 뜻까지만 알면 됩니다. JOIN 문장을 쓰는 연습은 팀 프로젝트에서 표가 둘 이상 필요해질 때 합니다.

확인 문제

- 1 다음 SQL 문장이 하는 일을 우리말로 쓰시오. `SELECT name, message FROM guestbook WHERE name = '지우' ORDER BY created_at DESC;`
- 2 CRUD 네 동작과 SQL 명령어(SELECT, INSERT, UPDATE, DELETE)를 짝지으시오.
- 3 `DELETE FROM guestbook;` 이 문장을 실행하면 어떤 일이 벌어지는지, 그리고 그것이 왜 위험한지 쓰시오.
- 4 영화 테이블(movies: 영화명, 장르, 총관객)에서 총관객이 100만 이상인 영화의 영화명을 총관객이 많은 순으로 가져오는 SQL 문장을 쓰시오.
- 5 AI가 짜 준 방명록 코드가 "연결은 되는데 저장이 안 됩니다". 코드를 고치기 전에 먼저 확인할 것 두 가지를 쓰시오.
- 6 "장르별 영화 편수"를 구하는 SQL 문장에서 GROUP BY 뒤에 올 열 이름과 SELECT에 쓸 집계 함수를 쓰시오.

I. 데이터 과학의 이해

4. 데이터 윤리 (14차시)

교과서의 정의 38-39쪽

"수집된 데이터의 분포가 고르지 못하고, 특정한 지역, 연령, 성별 등에 치우쳐 있을 경우 데이터에 편향성이 있다고 한다." (38쪽)

"실제 현실을 대표하지 못하고 특정한 방향으로 치우쳐 있는 데이터를 가지고 모델을 만들면, 특정 대상에게 유리하거나 불리한 모델이 만들어질 수 있다." (38쪽)

"학교 수업 중에 생성된 데이터는 학생의 것일까? 학교의 것일까? 서비스를 만든 기업의 것일까?" (39쪽)

→ 데이터가 치우치면 모델도 치우칩니다. 데이터가 자원이 된 시대에는 누구의 것인가부터가 쟁점입니다.

교과서의 세 가지 윤리 문제

문제	무엇이 잘못되나	우리 실습과의 접점
데이터 편향성	치우친 데이터로 만든 모델이 특정 대상에게 불리하게 작동한다	영화 모델의 첫날 스크린 수 변수
혐오 표현	사람들이 쓴 잘못된 언어를 인공지능이 그대로 학습한다	우리가 쓰는 AI 챗봇의 학습 데이터
데이터 소유권	내가 만든 데이터를 누가 소유하고 팔 수 있는지가 불분명하다	수업 중 폼으로 제출한 우리 응답

내 실습 속 네 장면

장면	쟁점	판단 기준
인증키	인증키는 요청을 보낸 사람이 누구인지 밝히는 서명이다. 영화 API의 하루 3,000회 한도는 키 단위로 걸린다. 키가 적힌 코드를 공개하면 남이 내 이름으로 요청을 보낼 수 있고, 한도 소진과 오·남용의 책임은 키 주인에게 돌아온다	키는 코드가 아니라 비밀 금고 (secrets)에 둔다. 기술 요령이 아니라 책임 관리다
데이터 민감도	급식 식단은 학교 단위 정보라 어느 학생이 무엇을 먹었는지가 없다. 개인 위치 기록은 한 건씩 익명이라도 시간순으로 이어 붙이면 특정 개인의 동선이 드러난다	민감도는 "공개되어 있는가"가 아니라 "이어 붙였을 때 개인을 추적할 수 있는가"로 판단한다
모델이 배우는 편향	스크린 배정은 대형 배급사에 유리한 사람의 결정이다. 그 변수로 학습한 모델은 "스크린을 많이 받을 영화가 성공한다"고 배우고, 예측이 다시 배정의 근거가 되면 작은 영화는 더 밀려난다	성능에 도움이 되는 변수와 써도 되는 변수는 항상 같지 않다. 치우침이 한 바퀴 돌아 굳어지는 구조를 본다
AI 코드의 책임	AI가 짠 코드가 잘못된 수치를 표시했다면 책임은 앱에 이름을 걸고 공개한 사람에게 있다	검증할 수 있는 사람만이 책임질 수 있다. 손계산 3종이 그 연습이었다

교과서의 정의 36쪽

"세계 연합(UN)은 전 세계 빈곤을 종식시키고, 지구를 보호하며, 2030년까지 모든 사람들이 평화와 번영을 누릴 수 있는 지속 가능한 미래를 만들기 위한 17개의 지속 가능 발전 목표(SDGs: Sustainable Development Goals)를 제시하였다."

→ 데이터는 문제를 만들기도 하지만, 기후·건강·교통 같은 세계의 문제를 진단하고 푸는 도구이기도 합니다. 같은 도구의 양면입니다.

팀 프로젝트 데이터 점검 목록

팀이 데이터를 고를 때 네 가지를 점검합니다. **개인정보**(개인 단위 정보가 없는가), **출처**(제공 기관과 수집 시점을 밝힐 수 있는가), **이용 약관**(공개·가공이 허용되는가), **편향**(특정 집단에 치우친 데이터가 아닌가). 데이터가 아무리 많아도 이 관문을 통과하지 못하면 주제가 될 수 없습니다.

확인 문제

- 1 급식 데이터는 전량 공개 앱으로 만들었지만 개인 위치 데이터라면 같은 방식이 위험합니다. 두 데이터의 민감도를 가르는 기준은 무엇입니까?
- 2 API 인증키를 코드에 적은 채 공개 저장소에 올리면 안 되는 까닭을 두 가지 쓰시오.
- 3 영화 흥행 모델을 "좋은 영화를 가려내는 모델"이라고 소개하면 왜 문제가 되는지 교과서 38쪽의 정의와 연결해 설명하시오.

II. 데이터 준비와 분석

1. 데이터 수집과 API (2.5차시)

데이터를 얻는 길은 크게 두 가지입니다. 공공데이터포털(data.go.kr)이나 기상자료개방포털에서 파일을 내려받는 길과, API로 요청해서 받는 길입니다.

	내려받기(CSV)	API 호출(JSON)
데이터의 시점	내려받은 순간의 복사본으로 멈춰 있다	호출할 때마다 최신이다
양	파일 전체	조건(날짜 등)으로 필요한 만큼만
형태	정형(표)	반정형(JSON), 표로 바꿔 쓴다
우리 실습	seoul.csv, kobis_movies.csv	KOBIS 박스오피스, 나이스 급식

API의 구조 — 요청과 응답의 약속

API(Application Programming Interface)는 프로그램끼리 데이터를 주고받는 접점입니다. 이 수업에서는 정해진 주소로 요청하면 정해진 양식(JSON)으로 응답이 온다는 약속으로 이해했습니다. 식당에 비유하면 메뉴판이 API 문서, 주문서가 요청, 서버가 응답입니다. 요청 주소 끝에 날짜 같은 조건을 붙이고, 응답과 함께 세 자리 상태 코드(200 성공, 404 없음, 429 과다 요청)가 옵니다.

	KOBIS 영화 API	나이스 급식 API
인증키	필요. 하루 3,000회 한도가 키 단위. 비밀 금고에 보관	없어도 호출 가능
주의할 점	관객 수가 글자로 온다	키 없는 호출은 한 번에 오는 건수에 제한이 있다

우리 실습 장면 — 오류 없이 잘려 오는 데이터

나이스 급식 API에 키 없이 다섯 달치를 한 번에 물으면, 응답은 "전체 82건"이라고 알려 주면서 목록에는 앞의 5건만 담아 보냅니다. 오류가 나지 않아 알아채기 어렵습니다. 건수 제한의 실물입니다. 그래서 조회 기간을 짧게 잡아 여러 번 부릅니다.

데이터 통합과 스냅샷

하루치 박스오피스 응답에는 시간 축이 없어 "변화"를 물을 수 없습니다. 일별 응답 365개를 한 표로 이은 것이 데이터 통합이고, 그렇게 어느 시점에 찍어 고정한 사본이 스냅샷(kobis_daily.csv)입니다. 행의 단위가 하루에서 영화 한 편

으로 바뀌면(kobis_movies.csv) 물을 수 있는 질문도 바뀝니다.

확인 문제

- 1
- 내려받은 CSV와 API 호출의 차이를 "시점"과 "양"의 관점에서 각각 한 문장으로 쓰시오.
- 2
- 키 없는 급식 API 호출에서 "전체 82건"인데 5건만 오는 현상을 무엇이라 부르며, 어떻게 대처합니까?

II. 데이터 준비와 분석

2. 데이터 탐색과 전처리 (1·6·11차시)

수집한 데이터는 그대로 쓰지 않습니다. 요약 통계와 그래프로 생김새를 살피고(탐색), 비어 있거나 극단적으로 벗어난 값을 확인해 처리합니다(전처리).

용어	뜻	우리 실습의 예
결측치	비어 있는 값	1950~1953년 서울 기온 공백(한국전쟁으로 관측 중단)
이상치	다른 값들과 동떨어진 값	1953년 연평균 0.6°C(그해 겨울 31일만 관측된 반쪽 값)
정규화	속성 간 단위·범위 차이를 없애 같은 기준으로 비교하게 하는 처리	삼진(수십~백 단위)과 타율(0.3 안팎)을 함께 쓸 때
형식 정리	셀 수 있는 모양으로 다듬는 일	메뉴 뒤 알레르기 번호 괄호 지우기, 글자로 온 관객 수를 숫자로

전처리 판단의 기준 — 믿을 수 없는 값 제거 vs 불리한 값 제거

1953년을 뺀 까닭은 그 값이 우리 결론에 불리해서가 아니라, 여름이 빠진 채 겨울 한 달만 관측되어 **연평균이라 부를 수 없는 값**이기 때문입니다. 관측일 300일 미만인 해를 빼는 규칙은 "믿을 수 없는 값"을 거르는 기준입니다. 결론에 불리한 값을 골라 빼는 것은 전처리가 아니라 조작입니다. 전처리에는 반드시 기준과 근거가 따라야 합니다.

우리 실습 장면 — 데이터에도 역사가 있다

연평균기온 그래프의 1950~1953년 구멍은 컴퓨터 오류가 아니라 한국전쟁으로 관측이 중단된 흔적입니다. 그리고 그 전처리가 모델 점수를 지탱했습니다. 관측일 필터를 켜면 회귀의 R²가 0.70, 끄면 0.39입니다(III-3에서 다시 봅니다).

확인 문제

- 1 서울 연평균기온 그래프에서 1950~1953년 구간이 비어 있는 까닭은 무엇입니까?
- 2 "믿을 수 없는 값 제거"와 "불리한 값 제거"의 차이를 1953년을 예로 들어 서술하시오.
- 3 선수 스캐트로 군집을 만들 때 정규화가 필요한 까닭을 쓰시오.

II. 데이터 준비와 분석

3. 시각화 — 질문과 그래프의 짝 (3·4차시)

그래프는 종류마다 답할 수 있는 질문이 다릅니다. 그래프를 고르는 기준은 보기 좋은 정도가 아니라 "내가 무엇이 궁금한가"입니다. 그리고 행의 단위(하루가 한 줄인 표, 영화가 한 줄인 표)가 바뀌면 그릴 수 있는 그래프가 바뀝니다.

답하는 질문	그래프	무엇을 보는가
한 영화의 관객은 개봉 후 어떻게 변하나	선 그래프	시간에 따른 변화(시계열)
1년 중 극장이 가장 붐빈 날은 언제인가	영역 그래프	전체 양의 흐름과 봉우리
이 기간 누적 TOP 10은 어느 영화인가	가로 막대	항목별 크기 비교
관객은 어느 요일에 몰리는가	히트맵(월×요일)	두 기준으로 접은 값의 진하기
10위권 영화의 장르 구성은 어떠한가	도넛	전체 중 비율(구성)
영화 대부분은 관객이 몇 명쯤인가	히스토그램	값의 분포
스크린을 많이 받은 영화가 관객도 많은가	산점도	두 속성의 관계
중앙값과 퍼짐, 튀는 값은	박스플롯	분포의 요약과 이상치

우리 실습 장면 — 무엇으로 재느냐가 메시지를 정한다

같은 216편인데 드라마는 편수(56편) 기준 도넛에서는 크고, 총 관객 기준 트리맵에서는 작아집니다. 도넛에서는 보이지도 않던 사극 1편(왕과 사는 남자, 총 관객 16,916,280명)이 트리맵에서는 큰 상자로 나타납니다. 그리고 10위권 일관객 합계가 가장 컸던 날은 2025년 12월 25일(1,347,645명)이었습니다. 이 수치는 그날 전체 관객이 아니라 일별 10위권 영화들의 합계입니다. 데이터의 범위까지 함께 말해야 정확한 해석입니다.

확인 문제

- 1 "영화 대부분은 관객이 몇 명쯤인가"에 알맞은 그래프와, "스크린 수와 관객 수의 관계"에 알맞은 그래프를 각각 쓰시오.
- 2 하루치 박스오피스 응답만으로 선 그래프를 그릴 수 없는 까닭은 무엇입니까?

4. 상관과 인과 (6차시)

교과서의 정의 70·72쪽

"상관계수는 상관관계의 강도와 방향을 나타내는 정량적인 단위로, 값의 범위는 -1부터 +1 까지이다." (70쪽)
"상관관계가 있는 데이터 속성 중에서 원인과 결과의 관계가 있는 데이터 속성 간 관계를 인과관계라고 한다." (72쪽)
→ 상관은 두 속성이 함께 변하는 정도를 재고, 인과는 그중에서 원인과 결과가 검증된 관계입니다. 함께 변한다고 원인인 것은 아닙니다.

상관계수	뜻
+1에 가까움	한쪽이 커지면 다른 쪽도 커진다(양의 상관)
0 근처	선형적인 관계가 거의 없다
-1에 가까움	한쪽이 커지면 다른 쪽은 작아진다(음의 상관)

교과서의 예 — 아이스크림과 물놀이 사고

아이스크림 판매량과 물놀이 사고는 함께 오르내리지만, 뒤에 여름철 기온이라는 공통 요인이 있을 뿐입니다. 인과를 주장하려면 상관과는 별도의 검증이 필요합니다. 연관 분석의 향상도 9.1(순대국과 석박지)도 인과의 증명이 아닙니다. 두 메뉴를 함께 정하는 식단표 작성자의 판단이 뒤에 있을 뿐입니다.

확인 문제

- 1 상관계수 -0.8과 +0.3 중 상관이 더 강한 것은 어느 쪽입니까? 까닭도 쓰시오.
- 2 "상관이 있다"와 "원인이다"가 다른 까닭을 교과서의 예로 설명하시오.

1. 기계학습과 모델 평가의 원칙 (7·9·11차시)

모델은 데이터에서 찾은 패턴을 간단한 형태(직선, 확률, 질문 순서, 묶음, 규칙)로 요약한 것입니다. 이 수업에서 만든 네 가지 틀은 다음과 같이 나뉩니다.

구분	틀	답의 형태	정답(레이블)	우리 실습
지도학습	회귀	숫자("몇 명", "몇 도")	있음	기온 예측, 영화 관객 수 예측
	분류	범주("성공/실패")	있음	흥행 성공 분류
비지도학습	군집	비슷한 것끼리의 묶음	없음	KBO 타자 유형
규칙 탐색	연관 분석	"A가 나오면 B도" 규칙	없음	급식 메뉴 짝

지도학습과 비지도학습을 가르는 것은 정답(레이블)의 유무입니다. 기온 회귀와 흥행 분류는 정답이 있는 데이터로 배우고, 선수 유형 묶기는 정답 없이 비슷한 것끼리 묶습니다.

원칙 1 — 점수는 학습에 쓰지 않은 데이터로 잴다

교과서의 정의 112쪽

"학습에 사용한 문제를 그대로 평가에 사용하면, 문제 해결 과정을 이해한 것인지 단지 문제를 외워서 맞힌 것인지 알 수 없어서 평가 결과를 신뢰할 수 없기 때문이다."

→ 데이터를 **훈련 데이터**(학습용)와 **테스트 데이터**(평가용)로 나눕니다. 시험 문제를 미리 보여 주고 시험을 보면 실력을 알 수 없는 것과 같습니다.

훈련 데이터에서만 점수가 높고 테스트 데이터에서는 낮은 현상을 **과대적합**이라 합니다. 데이터 몇 행만으로 학습한 모델이 훈련 데이터의 우연한 특징까지 외워 버릴 때 생깁니다.

원칙 2 — 큰 숫자를 만나면 비교할 상대부터 세운다

이 수업의 평가 습관은 이름을 바꿔 세 번 반복됩니다. 회귀의 R^2 는 "평균만 찍는 모델보다 얼마나 나은가", 분류의 정확도는 "전부 다수로 찍는 기준선을 넘는가", 연관의 향상도는 "우연히 겹칠 확률보다 나은가"입니다. 절대 점수가 아니라 비교값입니다.

원칙 3 — 성능이 갑자기 좋아지면 실력보다 반칙을 먼저 의심한다

예측 시점에 알 수 없는 정보가 입력에 섞이면 점수가 부풀려집니다. 이것을 **데이터 누수**(분류에서는 레이블 누수)라 합니다. 영화 흥행 예측에 개봉 첫 주 관객 수를 넣는 순간 회귀 R^2 는 0.24에서 0.90으로, 분류 정확도는 0.877에서

0.985로 급등합니다. 첫 주 관객 수는 개봉 전에는 알 수 없고 총 관객 수(정답의 재료)와 사실상 한 몸입니다. 시험지에 답이 인쇄된 채 시험을 본 것과 같습니다. 판단 기준은 점수의 크기가 아니라 **변수의 시점**입니다.

확인 문제

- 1 지도학습과 비지도학습을 가르치는 기준은 무엇이며, 회귀·분류·군집은 각각 어디에 속합니까?
- 2 학습에 쓴 데이터로 점수를 매기면 안 되는 까닭을 교과서 112쪽의 문장을 바탕으로 설명하시오.
- 3 "개봉 전 흥행 예측 모델"의 입력 변수 후보 (가) 장르 (나) 개봉 첫 주 관객 수 (다) 감독의 전작 성적 (라) 최종 누적 관객 수 가운데 누수에 해당하는 것을 모두 고르고 까닭을 쓰시오.

III. 데이터 모델링과 평가

2. 회귀 — 직선을 긋다 (6·7차시)

교과서의 정의 119·128쪽

"선형 회귀는 두 가지 이상의 속성 사이에 선 모양의 관계가 있다고 가정하고 데이터를 가장 잘 대표하는 선을 찾는 분석 방법이다." (119쪽)

"다중 선형 회귀(multiple linear regression)는 영향을 미치는 요인이 여러 개인 경우에 종속 변수를 설명하기 위해 여러 개의 독립 변수를 이용하는 회귀 분석이다." (128쪽)

→ 예측에 사용하는 값이 **독립 변수**(연도, 스크린 수), 예측하려는 값이 **종속 변수**(연평균기온, 관객 수)입니다. 독립 변수가 하나면 단순 선형 회귀, 여러 개면 다중 선형 회귀입니다.

회귀 직선은 $y = a \cdot x + b$ 꼴입니다. a가 **기울기**(가중치), b가 **절편**(편향)입니다. 기울기는 독립 변수가 1만큼

커질 때 종속 변수가 얼마나 변하는지를 뜻합니다. 우리 문제에서는 "1년에 몇 도", 100년 단위로 바꾸면 "100년에 몇 도"입니다. 최적의 직선은 다섯 점, 백 점의 오차를 가장 작게 만드는 a와 b를 찾은 결과이며, AI의 model.fit이 하는 일이 바로 그 계산입니다.

우리 실습 장면 — 창을 바꾸면 답이 3배 벌어진다

서울 연평균기온에 맞춘 직선의 기울기는 전체 114년 창에서 **+2.60°C/100년**, 최근 20년 창에서 **+8.14°C/100년**입니다. 둘 다 계산은 정확하며, 다른 질문에 답하는 직선입니다. 직선의 숫자를 만나면 어느 기간(창)에서 학습되었는지부터 묻습니다. 그리고 "+2.60°C/100년"은 "관측 기간 동안 100년당 평균 2.60°C씩 오르는 경향이 있었다"는 뜻이지, 해마다 반드시 오른다거나 100년 뒤가 확정된다는 뜻이 아닙니다.

외삽의 경고

직선은 학습 범위(1908~2025년) 밖에서도 주저 없이 숫자를 내놓지만, 그 구간의 성적표는 어디에도 없습니다. 슬라이더를 2100년까지 밀었을 때의 예측값은 참고일 뿐 보장이 아닙니다. R^2 가 높은 모델이 곧 미래를 잘 맞히는 모델은 아닙니다.

우리 실습 장면 — 변수를 더했는데 점수가 내려간다

영화 216편 가운데 학습에 쓰지 않은 66편으로 랜 다중 회귀의 테스트 R^2 는 첫날 스크린 수만 썼을 때 0.31, 개봉 전 변수 3종(스크린 수·상영 횟수·성수기)을 썼을 때 0.24로 오히려 떨어졌습니다(과대적합의 예고). 개봉 전 정보만으로는 처음 보는 영화의 흥행을 3분의 1도 설명하지 못합니다. 흥행은 원래 미리 알기 어렵다는 사실의 반영입니다.

확인 문제

- 1 회귀 직선의 기울기 $+2.60^\circ\text{C}/100\text{년}$ 의 뜻으로 옳은 것을 고르시오. ㉠ 올해 기온이 작년보다 2.60°C 높다 ㉡ 관측 기간 동안 100년당 평균 2.60°C 씩 오르는 경향이 있었다 ㉢ 100년 뒤 기온이 정확히 2.60°C 오른다고 확정된다
- 2 전체 창($+2.60$)과 최근 20년 창($+8.14$)의 기울기 중 하나만 제시하면 안 되는 까닭을 쓰시오.
- 3 독립 변수와 종속 변수를 영화 흥행 예측의 예로 설명하시오.

III. 데이터 모델링과 평가 ★ 자필 계산 문항의 원천

3. 회귀 모델의 평가 — 오차·MSE·결정계수 (8차시)

교과서의 정의 120·131·132쪽

"실제값과 예측값의 차이를 오차라고 하는데, 두 직선을 비교하여 오차가 더 작은 것을 선택해야 한다." (120쪽)

"평균제곱오차(MSE: Mean Squared Error)는 실제값과 예측값의 차이를 모두 제곱하여 평균한 값으로, 이 값이 작을수록 예측 성능이 좋다." (131쪽)

"결정 계수(R^2 score: R-squared score)는 회귀 모델이 실제 데이터와 얼마나 유사하게 예측하고 구체적으로 설명하는지를 나타낸다." (132쪽)

"결정 계수가 0에 가깝다면 회귀 모델이 데이터의 평균을 맞추는 정도로 예측했고, 회귀 모델의 유의미성이 떨어진다는 뜻이다." (132쪽)

네 단계의 계산

단계	계산	묻는 말
① 오차	실제값 - 예측값	이 예측은 얼마나, 어느 쪽으로 빗나갔나
② 부호 없애기	절댓값 → 절대오차의 평균(MAE) / 제곱 → 제곱오차	양수와 음수가 상쇄되지 않게 크기를 공정하게 비교하면?
③ MSE	제곱오차의 평균	이 모델은 평균적으로 얼마나 빗나가나
④ R ²	1 - (내 모델의 제곱오차 합 ÷ 평균 모델의 제곱오차 합)	평균만 찍는 모델보다 얼마나 나은가

왜 그냥 더하지 않는가. 오차 +3과 -3을 그냥 더하면 0이 되어 완벽한 예측처럼 보이지만, 실제로는 두 번 다 3만큼 빗나간 것입니다. 부호를 없애야 크기를 공정하게 잴 수 있습니다. **왜 하필 제곱인가.** 제곱은 큰 오차를 훨씬 크게 취급합니다. 오차 4는 제곱하면 16이 되어 오차 1 네 개(제곱합 4)보다 무겁습니다. 그래서 MSE는 "가끔 크게 틀리는 것"에 민감하고, 이상치 하나가 MSE와 R²를 크게 흔듭니다.

R²의 정체 — 게으른 모델과 비교하기

R²의 기준선은 데이터를 들여다보지도 않고 매번 **평균값만 찍는 모델**입니다. 이 게으른 모델의 제곱오차 합을 SST, 내 모델의 제곱오차 합을 SSE라 하면

$$R^2 = 1 - (SSE \div SST)$$

입니다. "내 직선은 평균만 찍는 모델이 내는 오차의 몇 %를 없앴는가"로 읽습니다.

계산 예

	1년차	2년차	3년차	4년차	5년차
실제(°C)	4	6	8	10	12
직선의 예측(°C)	5	6	7	10	12
오차(실제-예측)	-1	0	+1	0	0
평균(8)과의 차	-4	-2	0	+2	+4

SSE = 1 + 0 + 1 + 0 + 0 = **2**, SST = 16 + 4 + 0 + 4 + 16 = **40**. 따라서 R² = 1 - 2/40 = **0.95**. "내 직선은 평균만 찍는 모델이 내는 오차의 95%를 없앴다"입니다. MSE는 2 ÷ 5 = 0.4입니다.

R ² 눈금	뜻
1에 가까움	평균 모델의 오차를 대부분 없앴다
0	평균만 찍는 것과 다를 바 없다(SSE = SST)
음수	평균만 찍는 게으른 모델보다도 못하다(SSE > SST). R ² 는 음수가 될 수 있다

우리 실습 장면 — 0.70을 지탱한 것

기온 예측기의 R²는 관측일 필터를 켜면 **0.70**, 끄면 **0.39**입니다. 겨울 한 달만 관측된 1953년의 반쪽 연평균이 직선에서 멀리 떨어져 있고, 그 오차가 제공되면서 SSE를 키워 점수를 끌어내립니다. 모델의 성능을 지탱한 것은 알고리즘이 아니라 전처리였습니다. 영화 다중 회귀의 테스트 R² 0.24는 "개봉 전 변수 3종은 처음 보는 영화에서 평균만 찍기보다 오차를 4분의 1 정도 줄였을 뿐"이라는 뜻입니다.

R²가 높아도 남는 물음

R²는 가진 데이터 안에서의 성적입니다. 관측 범위 밖(외삽)에 대한 보장이 없고, 데이터의 퍼짐(SST)이 작으면 같은 SSE라도 R²가 뚝 떨어집니다. 큰 숫자를 만나면 무엇과 비교된 값인지, 어느 데이터에서 잤는지 확인합니다.

확인 문제

- 어느 예측기의 3일간 오차가 +3, -3, 0입니다. 오차를 그냥 더해 "완벽한 예측기"라고 주장할 때의 문제점과, 이 예측기의 MSE를 쓰시오.
- 평균만 찍는 모델의 제공오차 합이 40, 내 직선의 제공오차 합이 10일 때 R²는? 내 직선의 제공오차 합이 60이라면?
- 관측일 필터를 끄면 R²가 0.70에서 0.39로 떨어지는 까닭을 1953년과 "제공"의 성질을 근거로 설명하시오.

III. 데이터 모델링과 평가

4. 분류 — 로지스틱 회귀와 의사결정트리 (9차시)

교과서의 정의 135·136·138쪽

"분류 모델 중 이진 분류는 어떤 특성을 '된다' 또는 '되지 않는다' 두 가지 경우의 수 중 하나로 예측하는 것을 말한다." (135쪽)

"로지스틱 회귀는 선형 회귀 모델을 로지스틱 함수와 결합하여 각 범주에 해당할 확률을 바탕으로 분류하는 방법이다." (135쪽)

"레이블은 모델이 예측하고자 하는 정답 값을 의미한다." (138쪽)

→ 회귀는 "얼마나"에 숫자로, 분류는 "어느 쪽"에 범주로 답합니다. 같은 영화 데이터라도 "총 관객은 몇 명일까"는 회귀, "100만을 넘길까"는 이진 분류입니다. 묻는 형태가 모델을 정합니다.

모델	답하는 방식	특징
로지스틱 회귀	직선의 값을 시그모이드 함수로 0~1 사이의 확률로 눌러 담고, 문턱값(기본 0.5, 136쪽)으로 범주를 고른다	확률로 답한다. 문턱을 옮기면 판정이 바뀐다
의사결정트리	스무고개처럼 질문을 차례로 던져 가지를 나눈다	"모델이 무엇을 먼저 물었는지"가 그림으로 보인다(설명 가능)

라벨 기준은 사람이 정한다

"흥행 성공"은 데이터에 있던 사실이 아니라 사람이 기준을 정해 붙인 판단입니다. 216편 가운데 기준을 50만 명으로 두면 성공작이 30편(14%), **100만 명이면 23편(11%)**, 300만 명이면 7편(3%)입니다. 기준이 바뀌면 문제가 바뀌고 모델의 성적도 바뀝니다. 스팸 필터의 "스팸", 감염병 검사의 "양성"도 마찬가지로 사람이 정한 레이블입니다.

확인 문제

- 1

다음 중 분류 문제를 고르시오. ㉠ 내년 서울 연평균기온이 몇 도일지 예측하기 ㉡ 어떤 영화가 100만 관객을 넘길지 맞추기 ㉢ 어떤 영화의 총 관객 수를 예측하기
- 2

로지스틱 회귀의 답이 "확률"이라는 말의 뜻과, 문턱값의 역할을 쓰시오.
- 3

"라벨 기준은 사람이 정한다"를 흥행 성공의 예로 설명하시오.

5. 분류 모델의 평가 — 혼동행렬과 세 지표 (10차시)

교과서의 정의 139·140쪽

"오분류표란 각각의 실제 클래스와 예측 결과를 행렬로 나타낸 것이다." (139쪽)

"정확도는 전체 데이터 중 실제와 같게 예측한 데이터의 비율을 나타내며, 레이블별 분포가 균일하지 않은 경우 정확도로 모델을 평가하는 것은 부적절하다." (139쪽)

"문제 상황에 따라 적합한 성능 지표가 다르므로, 상황에 맞는 지표를 선택해야 한다." (140쪽)

네 칸 — 우리말이 먼저

"성공"을 양성(Positive)이라 할 때, 예측은 네 가지 중 하나로 결정됩니다. 약자 TP·FP·FN·TN은 True/False(예측이 맞음/틀림)와 Positive/Negative(성공/실패로 예측)의 조합입니다.

	예측: 성공	예측: 실패
실제: 성공	TP 맞다고 했는데 정말 맞음	FN 아니라고 했는데 사실 맞음 (놓친 성공작)
실제: 실패	FP 맞다고 했는데 틀림	TN 아니라고 했는데 정말 아님

세 지표 — 분자는 같고 분모가 다르다

지표	계산(140쪽 공식)	묻는 말
정확도	$(TP + TN) \div \text{전체}$	전체 중 얼마나 맞혔는가
정밀도	$TP \div (TP + FP)$	"성공"이라 말한 것 중 진짜 성공은 얼마인가
재현율	$TP \div (TP + FN)$	실제 성공작 중 얼마나 잡아냈는가

손계산에서 가장 자주 틀리는 곳이 분모입니다. 정밀도의 분모는 "성공이라 예측한 것"(표의 첫 번째 열), 재현율의 분모는 "실제 성공작"(표의 첫 번째 행)입니다.

계산 예

영화 50편 가운데 실제 성공 10편, 실패 40편입니다. 분류기는 성공 10편 중 7편을 성공으로 맞혔고(TP 7, FN 3), 실패 40편 중 5편을 성공이라 잘못 예측했습니다(FP 5, TN 35).

정확도 = $(7 + 35) \div 50 = 0.84$ · 정밀도 = $7 \div (7 + 5) = 0.58$ · 재현율 = $7 \div (7 + 3) = 0.70$. 그리고 아무 계산 없이 전부 "실패"로 찍는 기준선의 정확도는 $40 \div 50 = 0.80$ 입니다. 이 분류기는 기준선을 4%p 넘었고, 실제 성공 작 열 편 중 일곱 편을 잡았습니다.

정확도만 보면 놓치는 세 가지

놓치는 것	설명
기준선	라벨이 치우친 데이터에서는 전부 다수로 찍기만 해도 정확도가 높게 나옵니다. 전부 "실패"로 찍는 다수 결 기준선을 넘는지부터 확인합니다. 교과서 139쪽의 경고 그대로입니다
재현율	정확도가 높아도 정작 잡고 싶은 것(성공작, 감염자, 스팸)을 하나도 못 잡을 수 있습니다. 재현율은 따로 봅니다
누수	성능이 급등하면 개선이 아니라 반칙(레이블 누수)부터 의심합니다

우리 실습 장면 — 게으른 모델이 이긴다

영화 216편 중 성공작(기준 100만 명)은 23편(11%)입니다. 전부 "실패"로만 찍는 기준선의 정확도는 $193 \div 216 \approx 89\%$ 입니다. 개봉 전 변수 3종으로 학습한 로지스틱 회귀는 **87.7%**로 기준선보다 낮고, 성공 재현율은 **0.00**, 성공작 23편 중 한 편도 성공이라 말하지 못했습니다. 의사결정트리(깊이 3)는 0.908에 재현율 0.29로 기준선을 겨우 넘었고, 첫 주 관객 수를 넣는 순간 **0.985**로 급등합니다. 레이블 누수의 신호입니다.

지표 선택은 계산이 아니라 판단이다

정밀도와 재현율 중 무엇을 볼 것인가는 어느 쪽 틀림의 비용이 더 큰가에 대한 판단입니다. 교과서 140쪽은 스팸 필터라면 정밀도(멸절한 메일을 스팸함에 보내면 안 됨), 감염병 검사라면 재현율(감염자를 놓치면 안 됨)이라고 말합니다. 투자자는 "성공" 예측을 믿고 돈을 걸므로 정밀도를, 배급사 발굴팀은 성공작을 놓치는 것이 가장 아까우므로 재현율을 봅니다. 두 지표는 맞바꿈 관계입니다. 로지스틱 회귀의 문턱값을 내리면 재현율이 오르는 대신 정밀도가 내려갑니다.

확인 문제

- 1 영화 216편 중 성공작이 23편입니다. 전부 "실패"로 찍는 모델의 정확도와 성공 재현율을 구하시오.
- 2 로지스틱 회귀의 정확도 0.877을 "꽤 좋은 모델"이라 말할 수 없는 까닭을 두 가지 쓰시오.
- 3 "스팸 필터는 정밀도, 감염병 검사는 재현율"의 공통 원리를 한 문장으로 쓰시오.
- 4 메일 100통(스팸 10, 정상 90)을 분류한 결과 TP 8, FN 2, FP 9, TN 81일 때 정확도·정밀도·재현율을 구하고, 이 필터가 "전부 정상" 기준선보다 정확도가 낮는데도 더 쓸모 있다고 주장할 수 있는지 근거를 쓰시오.

6. 군집 — 정답 없이 비슷한 것끼리 (11차시)

교과서의 정의 146·154쪽

"데이터 속성 간의 유사성을 측정하여 유사한 데이터끼리 군집을 형성하는 것을 군집화라고 한다." (154쪽)

"k-평균 알고리즘은 k개의 군집을 구성하는 기계학습 알고리즘이다. 군집의 개수, 즉 k값에 따라 군집화 결과와 그에 따른 의미 해석이 달라지기 때문에 k값을 적절히 설정하는 것이 중요하다." (146쪽)

"군집 분석 결과를 해석하기 위해서는 데이터에 대한 깊은 이해가 필요하다." (154쪽)

→ 정답표(라벨) 없이 비슷한 것끼리 묶습니다. k는 사람이 정하고, 묶음의 이름과 의미도 사람이 붙입니다.

k-평균은 k개의 중심점을 놓고, 각 데이터를 가장 가까운 중심에 배정하고, 중심을 배정된 데이터의 평균으로 옮기는 일을 반복해 군집을 만듭니다. "가깝다"는 속성 값들의 **거리**로 잽니다. 그래서 두 가지 판단이 사람 몫으로 남습니다.

판단	왜 사람 몫인가	우리 실습
정규화	값이 큰 속성(삼진 수십~백 단위)이 거리 계산을 지배해, 타율(0.3 안팎)의 차이는 무시된다. 단위 차이를 없애야 기록의 유형이 기준이 된다	정규화 없이는 삼진·홈런이 군집을 지배
k와 이름	k에 정답은 없다. 점수(실루엣)는 묶음의 기하학적 조밀함과 분리만 잽 뿐 의미를 재지 못한다. 묶음의 이름은 스탯 프로필을 읽고 사람이 붙인다	거포형·발 빠른 교타형·중장거리형

실루엣 분석은 군집 안의 조밀함과 군집 사이의 분리를 계수로 재는 군집 평가 방법입니다. 값이 클수록 묶음이 서로 잘 떨어져 있다는 뜻이지만, 그 묶음이 말이 되는지는 알려 주지 않습니다.

우리 실습 장면 — 점수는 k=2, 해석은 k=3

2025 시즌 KBO 규정타석 타자 43명의 군집에서 실루엣 점수는 k=2가 **0.268**로 k=3의 **0.262**보다 근소하게 높습니다. 그런데 두 묶음(강타자 10명 대 나머지 33명)보다 세 묶음의 이야기가 훨씬 선명했습니다. 거포형 9명(홈런 27.6·장타율 0.542), 발 빠른 교타형 18명(도루 17.1), 중장거리형 16명(홈런 16.8·삼진 108.6). 점수가 시키는 답과 사람이 이해하는 답이 다를 때 어느 쪽을 따를지는 목적에 맞는 판단의 문제입니다.

확인 문제

- 지도학습과 비교해 군집이 다른 점을 "정답"이라는 낱말을 써서 설명하시오.
- 정규화를 하지 않으면 군집이 어떻게 되는지 삼진과 타율을 예로 설명하시오.
- 실루엣 점수는 k=2가 높는데 해석은 k=3이 더 말이 됩니다. 이 상황이 알려 주는 바를 쓰시오.

7. 연관 분석 — 지지도·신뢰도·향상도 (12차시)

교과서의 정의 159·160쪽

"지지도는 두 개의 사건이 동시에 발생하는 비율이며 ..." (159쪽)

"신뢰도는 규칙의 결과 부분이 발생할 가능성을 측정한다." (159쪽)

"두 사건 A와 B가 서로 영향을 주지 않고 독립적으로 발생한다면, 향상도는 1에 가까워진다." (160쪽)

연관 분석은 "무엇과 무엇이 함께 나타나는가"를 세는 분석(장바구니 분석)입니다. 하루 식단이 장바구니 1건, 메뉴 하나가 상품 하나입니다. 규칙 "A → B"에 대해 세 지표는 나눗셈 세 번입니다.

지표	계산	나누는 수(분모)	묻는 말
지지도	A와 B가 함께 나온 횟수 ÷ 전체	전체 건수	이 조합, 다룰 만큼 자주 나오는가
신뢰도	A와 B가 함께 나온 횟수 ÷ A가 나온 횟수	A가 나온 건수	A가 나오면 B도 나오는가
향상도	신뢰도 ÷ (B가 나온 횟수 ÷ 전체)	B의 기본 등장률	우연히 겹칠 확률보다 나은가. 1이면 우연과 같음

계산 예

급식 20일 가운데 카레가 5일, 단무지가 8일, 둘이 함께 나온 날이 4일이라고 합시다. "카레 → 단무지"의 지지도 = $4 \div 20 = 0.20$, 신뢰도 = $4 \div 5 = 0.80$, 단무지의 기본 등장률 = $8 \div 20 = 0.40$, 향상도 = $0.80 \div 0.40 = 2.0$. 카레가 나온 날 단무지가 나올 확률(80%)은 아무 날(40%)의 2배입니다. 우연 이상의 짝입니다.

시험에 나오는 대비	가르는 기준
신뢰도 vs 향상도	"절반 넘게 같이 나온다"(높은 신뢰도)가 아무 정보도 아닐 수 있다. B가 원래 자주 나오는 항목이면 향상도가 1 근처로 내려온다
A→B vs B→A	규칙에는 방향이 있다. 분모(A가 나온 건수)가 바뀌므로 신뢰도가 달라진다. 향상도는 양방향에 같다
높은 향상도 vs 적은 등장 횟수	동시 등장이 1회뿐이면 향상도가 크게 과장된다. 그래서 최소 지지도 문턱(예: 동시 5회 이상)으로 한 번의 우연을 먼저 거른다

우리 실습 장면 — 김치의 배신

당곡고 중식 154일에서 **제육볶음 → 배추김치**는 신뢰도 $0.56(5 \div 9)$ 인데 향상도 0.99 입니다. 배추김치는 원래 154일 중 86일(56%)에 나오므로 제육볶음이 나온 날과 다를 바가 없습니다. 반면 **순대국 → 석박지**는 신뢰도 $1.00(5 \div 5)$, 향상도 $9.1(1.00 \div (17 \div 154))$ 입니다. 순대국이 나온 5일 모두 석박지가 함께 나온 진짜 짝꿍입니다. 역방향 석박지 → 순대국의 신뢰도는 $5 \div 17 \approx 0.29$ 입니다. 배추김치와 짝두기는 우연이라면 약 14.5일 겹쳐야 하는데 동시 등장이 0일입니다. "주력 김치는 하루 한 종류"라는 급식실 운영 원칙이 데이터에서 거꾸로 드러납니다.

확인 문제

- 1 매점 20일 기록에서 콜라 8일, 포테토칩 10일, 둘 다 6일입니다. "콜라 → 포테토칩"의 지지도·신뢰도·향상도를 구하시오.
- 2 신뢰도가 0.56으로 높은데도 "제육볶음 → 배추김치"를 규칙이라 부를 수 없는 까닭을 쓰시오.
- 3 동시 등장 1회로 향상도 154가 나온 쌍을 순대국·석박지(9.1)보다 17배 강한 규칙이라 말할 수 없는 까닭과, 그래서 무엇을 먼저 정하는지 쓰시오.

모델 도감 — kNN·랜덤 포레스트·XGBoost

 교재에서 추가한 내용

교과서가 다루는 모델은 회귀·로지스틱 회귀·의사결정트리·k-평균·연관 규칙입니다. 우리 교재의 모델 도감은 실제 분석 현장에서 자주 쓰이는 세 모델을 더했습니다. 새 이름이 셋 나오지만 새 수학은 없습니다. 거리(군집), 트리(분류), 오차(회귀 평가)를 이미 손으로 다뤘기 때문입니다.

모델	어디서	한 줄 원리
선형·다중 회귀	6~8차시	과거 데이터에 직선을 긋는다
로지스틱 회귀	9~10차시	직선을 확률(0~1)로 눌러 담는다
의사결정트리	9~10차시	스무고개처럼 질문을 던져 나눈다
k-평균 군집	11차시	거리로 비슷한 것끼리 묶는다
k-최근접 이웃(kNN)	모델 도감	가장 가까운 k명의 다수결을 따른다
랜덤 포레스트	모델 도감	서로 다른 나무 여러 그루의 투표
XGBoost	모델 도감	남은 오차를 다음 나무가 이어서 학습

k-최근접 이웃(kNN) — 가장 가까운 이웃들에게 물어본다

kNN은 k-Nearest Neighbors의 약자로, 교과서 135쪽에서 분류 모델의 하나로 이름을 소개한 모델입니다. 새 영화가 성공할지 궁금하면, 속성이 가장 비슷한(거리가 가까운) 과거 영화 k편을 찾아 그 **다수결**을 따릅니다. 학습이라 할 것이 거의 없고, 판정 순간에 거리를 재는 것이 전부입니다.

k	무슨 일이 벌어지나
k = 1	가장 가까운 한 편이 전권을 쥔다. 그 한 편이 특이한 영화라면 판정도 흔들린다. 우연에 가장 민감하다
k = 전체(216)	"가깝다"는 정보가 사라지고 언제나 다수 클래스로 판정한다. "전부 실패로 찍는 기준선"과 같아진다
좋은 k	이 양 끝 사이. 우연 한 편에 흔들리지 않을 만큼 크게, 이웃답다는 정보가 살아 있을 만큼 작게. 사람이 정한다

kNN의 급소는 정규화입니다. 스크린 수(수백 단위)와 첫 주 관객(수십만 단위)을 그대로 재면 큰 단위가 거리 계산을 지배합니다. 거리로만 판단하는 모델이라 군집 때보다도 정규화가 더 절실합니다.

랜덤 포레스트 — 나무 한 그루가 아니라 숲의 투표

트리 하나는 이해하기 쉽지만 학습 데이터의 우연한 특징까지 외워 버리기 쉽습니다. 랜덤 포레스트(Random Forest)는 이 약점을 수로 해결합니다. 전체 데이터에서 중복을 허용해 무작위로 표본을 다시 뽑는 방식(부트스트랩)으로 조금씩 다르게 공부한 트리 수십~수백 그루를 기르고, 새 데이터가 오면 전원 투표로 판정합니다. 이렇게 여러 모델을 묶는 방식을 앙상블(ensemble)이라 부릅니다.

나무 수	다수결이 틀릴 확률(각 나무 오답률 30%, 실수가 서로 독립일 때)
1그루	30%
5그루	약 16%
25그루	약 2%
101그루	0.1% 미만

같은 실력의 나무라도 수만 늘리면 오답이 줄어듭니다. 단 조건이 둘입니다. 각 나무가 찍기보다는 나아야 하고(반타작 이하면 모을수록 나빠집니다), 실수가 서로 겹치지 않아야 합니다. 표본을 무작위로 흔드는 것이 두 번째 조건을 만드는 장치입니다. 대신 잃는 것도 있습니다. 트리 한 그루는 "무엇을 먼저 물었는지"를 읽을 수 있었지만, 수백 그루의 숲은 그 설명을 한눈에 보여 주지 못합니다. 성능과 설명 가능성 사이의 선택도 사람의 판단입니다.

XGBoost — 틀린 문제를 다음 나무가 다시 푼다

XGBoost는 eXtreme Gradient Boosting의 약자로, 표 형태 데이터 분석 대회에서 우승을 거듭해 온 대표 모델입니다. 랜덤 포레스트가 나무들을 한꺼번에 길러 투표시킨다면, 부스팅(boosting)은 나무를 한 그루씩 차례로 기릅니다. 첫 나무가 문제를 풀면, 두 번째 나무는 첫 나무가 남긴 오차만 집중해서 배우고, 세 번째 나무는 그러고도 남은 오차를 배웁니다. 8차시에 손으로 계산한 그 "오차"가 여기서의 다음 나무의 교재가 됩니다. 최종 예측은 투표가 아니라 나무들의 예측을 더한 합입니다. 이름의 gradient(기울기)는 오차가 가장 빨리 줄어드는 방향을 계산해 그쪽으로 나아간다는 뜻입니다.

잘 배우는 모델일수록 잘 외운다

오차를 집요하게 줄이는 모델은 학습 데이터의 우연까지 외울 위험도 그만큼 큼니다. 그래서 강한 모델일수록 원칙이 더 중요해집니다. 학습에 쓰지 않은 데이터로 점수를 재고, 성능이 급등하면 실력보다 누수를 먼저 의심합니다.

모델 오디션의 규칙 — 팀 프로젝트에서 그대로 쓴다

규칙	뜻
같은 시험	같은 데이터, 같은 나누기, 같은 지표로 시험한다
기준선을 첫 줄에	"전부 실패로 찍기" 행을 표의 맨 위에 두고, 기준선을 넘지 못한 모델부터 지운다
재현율을 본다	남은 모델끼리는 정작 잡고 싶은 것을 몇이나 잡았는지 비교한다
설명 가능성·안정성	판단을 설명할 수 있는가(트리는 보여 주고 숲은 감춘다). 학습용·시험용을 바꿔 가며 여러 번 재어 평균이 비슷하면 점수의 폭이 좁은 쪽을 고른다. 한 번의 성적은 우연일 수 있다

확인 문제

- 1 kNN에서 k를 데이터 전체 수까지 키우면 어떤 모델과 같아집니까? 까닭도 쓰시오.
- 2 랜덤 포레스트가 나무 한 그루보다 나아지기 위한 두 가지 조건을 쓰시오.
- 3 랜덤 포레스트와 XGBoost의 차이를 "투표"와 "덧셈"이라는 낱말을 써서 설명하시오.
- 4 모델 오디션 표에서 기준선 행을 맨 위에 두는 까닭을 10차시의 실측(89% 대 87.7%)과 연결해 쓰시오.

A. 실측 수치 한 장 — 숫자마다 장면을 말할 수 있는가

지필 문항은 수업에서 함께 본 실측 수치로만 출제됩니다. 아래 숫자가 어떤 장면의 것이었는지 말로 설명할 수 있으면 준비가 끝난 것입니다.

수치	어디서	무엇을 말하나
+2.60 ↔ +8.14 °C/100년	기온 회귀, 전체 114년 창 ↔ 최근 20년 창	학습 창이 다르면 기울기가 3배 넘게 벌어진다. 직선의 숫자는 어느 창에서 왔는지부터 묻는다
R² 0.70 ↔ 0.39	기온 예측기, 관측일 필터 켜 ↔ 끄	1953년(겨울 31일만 관측)의 반쪽 값이 제곱오차를 키운다. 전처리가 성능을 지탱했다
1950~1953년 공백	서울 기온	한국전쟁으로 관측 중단(결측). 컴퓨터 오류가 아니다
테스트 R² 0.31 → 0.24 → 0.90	영화 다중 회귀, 스크린 수만 → 개봉 전 3종 → +첫 주 관객	변수를 더했는데 하락(과대적합 예고), 첫 주 관객을 넣자 급등(데이터 누수)
23편(11%), 기준선 89%	영화 216편, 성공 기준 100만 명	전부 "실패"로 찍어도 89%. 라벨 기준은 사람이 정한다
0.877, 재현율 0.00	로지스틱 회귀(개봉 전 3종)	기준선보다 낮고 성공작을 한 편도 못 잡는다. 정확도만으로는 부적절
0.908, 재현율 0.29	의사결정트리(깊이 3)	기준선을 겨우 넘고 성공작 일부를 잡기 시작
0.985	로지스틱 + 첫 주 관객	레이블 누수. 급등은 반칙 신호
실루엣 0.268 ↔ 0.262	KBO 타자 43명, k=2 ↔ k=3	점수는 k=2, 해석은 k=3. 묶음의 이름은 사람이 붙인다
신뢰도 0.56, 향상도 0.99	제육볶음 → 배추김치(154일, 9일·86일·동시 5일)	김치의 배신. 배추김치는 원래 56%의 날에 나온다
신뢰도 1.00, 향상도 9.1	순대국 → 석박지(5일·17일·동시 5일)	진짜 짬뽕. 역방향 신뢰도는 0.29
기대 14.5일, 실제 0일	배추김치 ↔ 깍두기	음의 연관. 주력 김치는 하루 한 종류
하루 3,000회	KOBIS 인증키 호출 한도	키 단위의 책임. 키는 비밀 금고에
전체 82건, 목록 5건	나이스 급식 API 키 없는 호출	건수 제한. 오류 없이 잘려 온다
2025-12-25, 1,347,645명	10위권 일관객 합계 최대일	데이터에 달력의 사건이 찍힌다. 범위(10위권 합계)까지 말해야 정확

B. 핵심 용어

용어	뜻
데이터 기반 의사 결정	데이터를 수집·분석하여 의사 결정을 내리는 것
정형·반정형·비정형	구조가 명확한 표 · 구조는 있으나 바꿀 수 있는 형태(JSON·XML) · 구조를 정의하기 어려운 데이터
API	정해진 주소로 요청하면 정해진 양식(JSON)으로 응답하는 약속. 인증키는 요청자를 증명하는 문자열
데이터셋·데이터베이스·테이블	한 주제의 데이터 집합 · 여럿이 공유하도록 통합 관리되는 데이터 집합 · 데이터베이스 안의 표 하나
CRUD	생성·읽기·갱신·삭제. SQL의 INSERT·SELECT·UPDATE·DELETE
기본 키 · 외래 키	행 하나를 유일하게 가리키는 열(id) · 다른 표의 기본 키를 가리켜 표와 표를 잇는 열
SQL	테이블에 데이터를 넣고(INSERT) 꺼내고(SELECT) 고치고(UPDATE) 지우고(DELETE) 지시하는 언어. WHERE는 조건, ORDER BY는 정렬, GROUP BY는 묶어서 집계
권한 정책(RLS)	표마다 누가 어떤 동작을 할 수 있는지 정해 둔 규칙. 정책이 없으면 모든 출입이 막힌다
데이터 무결성	잘못된 값이 들어오지 않도록 제약을 걸어 올바름을 지키는 것
데이터 편향성	분포가 특정 지역·연령·성별 등으로 치우친 것. 모델의 치우침으로 이어진다
결측치·이상치	비어 있는 값 · 다른 값들과 동떨어진 값
정규화	속성 간 단위·범위 차이를 없애 같은 기준으로 거리를 재계 하는 처리
상관계수	상관의 강도와 방향을 -1~+1로 나타낸 수치
인과관계	상관 중에서 원인과 결과가 검증으로 확인된 관계
독립 변수·종속 변수	예측에 사용하는 값 · 예측하려는 값
훈련·테스트 데이터	학습에 쓰는 데이터 · 점수를 매기려고 따로 떼어 둔 데이터
과대적합	훈련 데이터의 우연까지 외워 훈련에서만 점수가 높은 현상
데이터 누수(레이블 누수)	예측 시점에 알 수 없는 정답 관련 정보가 입력에 섞이는 반칙

오차·MAE·MSE	실제값-예측값 · 절대오차의 평균 · 제곱오차의 평균(큰 실수에 민감)
결정계수(R^2)	$1 - (\text{내 모델의 제곱오차 합} \div \text{평균 모델의 제곱오차 합})$. 평균 모델 대비 개선율
레이블	모델이 예측하려는 정답 값. 기준은 사람이 정한다
문턱값	확률을 범주로 바꾸는 경계(기본 0.5)
혼동행렬(오분류표)	실제 클래스와 예측 결과를 네 칸으로 나타낸 표
정확도·정밀도·재현율	$(TP+TN) \div \text{전체}$ · $TP \div (TP+FP)$ · $TP \div (TP+FN)$
다수결 기준선	전부 다수 클래스로 찍는 모델의 정확도. 분류기가 넘어야 할 출발선
군집화·k-평균	유사한 데이터끼리 묶는 것 · k개의 중심을 반복 조정하는 알고리즘
실루엣 분석	군집 내 조밀함과 군집 간 분리를 계수로 재는 군집 평가 방법
지지도·신뢰도·향상도	함께 나온 비율 · A가 나온 날 중 B도 나온 비율 · 신뢰도 $\div$ B의 기본 등장률(1이면 우연)
최소 지지도	한 번의 우연을 거르는 문턱
앙상블·부스팅	여러 모델의 답을 모아 하나의 판정을 만드는 방식 · 앞 모델의 오차를 다음 모델이 이어 학습하는 방식

부록

C. 확인 문제 정답

I-1

1. 모델 평가하기. 2. 평가 결과가 만족스럽지 않으면 데이터 수집이나 문제 정의로 되돌아갈 수 있고, 이미 정리된 데이터라면 전처리를 건너뛸 수도 있다. 3. ㉠.

I-2

1. 식단표는 정형, 사진은 비정형, JSON 응답은 반정형. 2. 데이터 구조를 쉽게 변경할 수 있고, 필요하면 표 형태로 쉽게 변환할 수 있기 때문.

I-3

1. 굵직한 CSV 파일이 데이터셋, 학급 수파베이스 프로젝트가 데이터베이스, 방명록 표가 테이블. 2. 여러 사람이 동시에 입력해도 서로의 작업을 덮지 않고 각각 쌓인다. 데이터가 한곳에 누적되고 조건으로 검색해 읽을 수 있다(그 밖에 버전 관리, 무

결성, 권한). 3. 갱신·삭제는 데이터를 바꾸는 동작이라 아무나 할 수 있으면 남의 글을 지울 수 있다. 권한을 나누는 "데이터 보안 강화".

I-3 보충(SQL)

1. 방명록 테이블에서 이름이 '지우'인 글의 이름과 소감을 작성 시각이 낮은 순(최신순)으로 가져온다. 2. 생성-INSERT, 읽기-SELECT, 갱신-UPDATE, 삭제-DELETE. 3. WHERE가 없어 방명록의 모든 행이 지워진다. 조건 없는 삭제·갱신은 테이블 전체에 적용되므로 기본 키로 행을 특정해야 한다. 4. SELECT 영화명 FROM movies WHERE 총관객 >= 1000000 ORDER BY 총관객 DESC; 5. 표 이름·열 이름이 실제 표와 같은지(AI가 지어내지 않았는지), 그 표에 추가 (INSERT) 권한 정책이 열려 있는지. 6. GROUP BY 장르, COUNT(*).

I-3 보충(SQL) 영양사 선생님의 부탁

장면 1. SELECT 요일, AVG(칼로리) AS 평균칼로리 FROM meals WHERE 식사 = '중식' GROUP BY 요일 ORDER BY 평균칼로리 DESC; 장면 2. (가) GROUP BY 요일은 요일이 같은 행들을 한 묶음으로 접어 요일마다 한 행만 남긴다. 날짜는 한 묶음 안에 값이 여러 개(약 31개)라 한 칸에 표시할 수 없으므로, GROUP BY에 없는 열은 COUNT·AVG 같은 집계 함수로 감싸야 한다. (나) SELECT 요일, COUNT(*) AS 일수 FROM meals WHERE 식사 = '중식' GROUP BY 요일;

I-4

1. 공개 여부나 양이 아니라, 기록을 이어 붙였을 때 특정 개인을 추적할 수 있는가. 2. 인증키는 요청자를 식별하는 값이라 공개되면 남이 내 이름으로 호출할 수 있다. 호출 한도(일 3,000회)가 키 단위라 남이 쓰면 한도가 소진되고 오·남용의 책임도 키 주인에게 돌아온다. 3. 스크린 배정이라는 사람의 결정에 담긴 치우침을 학습해, 예측이 다시 배정의 근거가 되면 작은 영화에 불리한 구조가 강화된다. 치우친 데이터로 만든 모델은 특정 대상에게 불리하게 작동한다(38쪽).

II-1

1. 시점: 내려받은 파일은 그 순간의 복사본으로 멈춰 있고 API는 호출할 때마다 최신이다. 양: 파일은 전체를 받고 API는 조건으로 필요한 만큼만 받는다. 2. 건수 제한. 조회 기간을 짧게 잡아 여러 번 호출한다.

II-2

1. 한국전쟁으로 관측이 중단되어 유효한 값이 없다(결측). 2. 1953년은 겨울 한 달만 관측되어 연평균이라 부를 수 없는 값이라 뺐다(믿을 수 없는 값 제거). 결론에 불리하다는 이유로 값을 고르는 것은 전처리가 아니라 조작이다. 3. 값이 큰 속성(삼진)이 거리 계산을 지배해 타울 같은 작은 단위의 차이가 무시되기 때문.

II-3

1. 히스토그램, 산점도. 2. 하루치 응답에는 시간 축이 없어 변화를 물을 수 없다. 일별 응답을 한 표로 이어야(데이터 통합) 선 그래프가 된다.

II-4

1. -0.8 . 상관의 강도는 부호가 아니라 절댓값의 크기로 본다. 2. 아이스크림 판매량과 물놀이 사고는 함께 오르내리지만 뒤에 여름철 기온이라는 공통 요인이 있을 뿐이다. 인과 주장에는 별도의 검증이 필요하다.

III-1

1. 정답(레이블)의 유무. 회귀·분류는 지도학습, 군집은 비지도학습. 2. 문제를 외워서 맞힌 것인지 이해한 것인지 알 수 없어 평가 결과를 신뢰할 수 없다. 3. (나), (라). (라)는 정답 그 자체이고 (나)는 개봉 전에 알 수 없는 미래 정보다.

III-2

1. ㉠. 2. 학습 창이 다르면 기울기가 3배 넘게 달라지므로, 하나만 제시하면 창 선택에 따라 결론이 달라진다는 사실을 감추게 된다. 3. 독립 변수는 스크린 수·상영 횟수·장르처럼 예측에 쓰는 값, 종속 변수는 총 관객 수처럼 예측하려는 값.

III-3

1. $+3$ 과 -3 이 상쇄되어 합이 0일 뿐 두 번 다 3만큼 빛나갔다. $MSE = (9 + 9 + 0) \div 3 = 6$. 2. $1 - 10/40 = 0.75$. $1 - 60/40 = -0.5$ (평균 모델보다 못하다). 3. 1953년은 겨울 한 달만 관측된 반쪽 값이라 직선에서 멀리 떨어져 있고, 그 오차가 제공되면서 제공오차 합을 크게 키워 R^2 를 끌어내린다.

III-4

1. ㉠. 2. 0과 1 사이의 값으로 "성공일 가능성"을 내놓는다는 뜻. 문턱값은 그 확률을 성공/실패 범주로 바꾸는 경계다. 3. 성공의 기준(50만·100만·300만)을 사람이 정하며, 기준에 따라 성공작 수($30 \cdot 23 \cdot 7$ 편)와 모델의 성적이 달라진다.

III-5

1. 정확도 $193 \div 216 \approx 0.89$, 재현율 $0 \div 23 = 0.00$. 2. 전부 실패로 찍는 기준선 0.89보다 낮다. 성공 재현율이 0.00으로 성공작을 한 편도 잡지 못한다. 3. 지표 선택은 틀린 예측의 비용이 어느 쪽이 큰가에 대한 판단이다. 4. 정확도 $89/100 = 0.89$, 정밀도 $8/17 \approx 0.47$, 재현율 $8/10 = 0.80$. 기준선(0.90)보다 정확도는 낮지만 목적(스팸 차단)에 맞는 지표인 재현율이 0.80이고 기준선의 재현율은 0이므로 더 쓸모 있다고 주장할 수 있다. 대가는 정상 메일 9통이 스팸함에 가는 것(정밀도 0.47).

III-6

1. 지도학습은 정답(레이블)이 있는 데이터로 배우지만 군집은 정답 없이 비슷한 것끼리 묶는다. 2. 삼진(수십~백 단위)이 거리 계산을 지배해 타율(0.3 안팎)의 차이는 무시되고, 삼진 수가 비슷한 선수끼리만 묶인다. 3. k 에 유일한 정답은 없으며, 점수와 해석이 다를 때는 사람이 목적에 맞게 판단해야 한다.

III-7

1. 지지도 $6/20 = 0.30$, 신뢰도 $6/8 = 0.75$, 향상도 $0.75 \div (10/20) = 1.5$. 2. 배추김치는 원래 154일 중 86일(56%)에 나오므로 제육볶음이 나온 날의 56%는 우연과 같다(향상도 0.99). 3. 동시 등장 1회는 우연일 가능성을 배제할 수 없고 등장 횟수가 적을수록 향상도가 과장된다. 그래서 최소 지지도 문턱을 먼저 정한다.

모델 도감

1. 전부 다수 클래스로 찍는 기준선 모델. "가깝다"는 정보가 사라지고 언제나 다수결이 되기 때문. 2. 각 나무가 찍기보다는 나아야 하고, 나무들의 실수가 서로 겹치지 않아야 한다. 3. 랜덤 포레스트는 한꺼번에 기른 나무들의 투표로 판정하고, XGBoost는 앞 나무가 남긴 오차를 다음 나무가 이어 배워 예측을 더한 합으로 판정한다. 4. 로지스틱 회귀의 87.7%처럼 정확도가 높아 보여도 기준선 89% 아래면 다수결만 못한 것이므로, 기준선을 먼저 세워야 점수의 의미가 생긴다.